

# Détection simultanée de l'ombre et la végétation sur des images aériennes couleur en haute résolution

Tran-Thanh Ngo, Christophe Collet, Vincent Mazet  
ICube, Université de Strasbourg, CNRS ;  
300 boulevard Sébastien Brant, CS 10413, 67412 Illkirch, France  
ttngo@unistra.fr, c.collet@unistra.fr, vincent.mazet@unistra.fr

## Résumé

*Nous proposons une nouvelle méthode pour détecter simultanément les zones d'ombre et de végétation dans des images de télédétection. Plusieurs indices d'ombre et de végétation sont fusionnés grâce à la théorie de Dempster-Shafer (DS) afin d'augmenter la fiabilité et la précision de la segmentation. La fusion de DS étant une méthode pixelique, elle est incorporée dans un contexte markovien pour obtenir une segmentation optimale et régularisée. Les évaluations sur des images aériennes montrent clairement que cette méthode est robuste et précise.*

## Mots Clef

Télédétection, Dempster-Shafer, champs de Markov cachés, détection d'ombre, détection de végétation, segmentation multivariée.

## Abstract

*We propose a new method to simultaneously detect shadows and vegetation in remote sensing images. Several shadow and vegetation indices are merged with the Dempster-Shafer (DS) theory so as to increase the reliability and accuracy of the segmentation. The per-pixel DS fusion is incorporated in a Markovian context to obtain an optimal and regularized segmentation result. Evaluation on aerial images clearly shows that this new method is robust and accurate.*

## Keywords

Remote sensing, Dempster-Shafer, Markov random field, shadow detection, vegetation detection, multivariate segmentation.

## 1 Introduction

Les catastrophes naturelles ou l'impact de l'activité humaine sur l'environnement nécessitent une observation de la Terre toujours plus complète. Dans ce cadre, l'étude de l'ombre et de la végétation sur des images aériennes

ou satellitaire permet d'obtenir des indices géométriques et sémantiques sur l'état des bâtiments après une catastrophe naturelle. Ce travail est consacré à la détection simultanée de l'ombre et de la végétation sur des images aériennes RVB (rouge, vert, bleu) et en haute résolution (35 cm/pixel). Les images segmentées ainsi obtenues permettront ensuite d'extraire la forme de bâtiments ; il est donc important d'obtenir des cartes de segmentation précises avant et après la catastrophe.

Les ombres sont dues aux occlusions totales ou partielles de la lumière incidente par les objets. Ces dernières années, plusieurs travaux ont apporté des contributions en détection de l'ombre, e.g. [2, 7, 8, 9, 14, 27, 30]. En général, ces méthodes considèrent que l'ombre assombrit les zones exposées mais ne modifie pas leur chrominance. Ainsi, les zones ombrées peuvent être détectées en choisissant un espace de couleurs possédant une meilleure séparation entre chrominance et intensité que l'espace RVB. Les espaces HSV [9],  $c_1c_2c_3$  [27], YUV [7], RVB normalisé [7], ou une combinaison de ces espaces [30] permettent une bonne séparation. D'autres auteurs ont proposé d'exploiter le fait que les zones ombrées ont généralement une radiance plus faible sur tout le spectre et que l'illumination du capteur diminue avec la longueur d'onde à cause de la dispersion [1]. À partir de ces hypothèses, différents indices ont été proposés pour quantifier l'ombre dans les images [8, 14, 17]. La plupart de ces méthodes sont simples à mettre en œuvre et peu coûteuses en calcul. Cependant, elles conduisent généralement à des performances peu satisfaisantes sur des images réelles car d'une part elles travaillent ponctuellement au niveau du pixel et sont donc sensibles au bruit et d'autre part elles n'exploitent pas les informations géométriques de l'image.

Par ailleurs, il existe plusieurs indices pour estimer la densité de la végétation à partir d'images aériennes et satellitaires, largement utilisés depuis de nombreuses années. En plus du très populaire NDVI (*normalized difference vegetation index*) [24, 31], d'autres indices utilisant uniquement les bandes spectrales rouge, verte et bleue ont été proposées dans la littérature. Parmi eux, citons les indices CIVE (*color index of vegetation extraction*) [15], ExG (*excess green index*) [32] et ExGR (*excess green minus excess red*) [18]. Ces indices permettent d'accentuer une couleur particulière

---

Nous remercions le Service régional de traitement d'image et de télédétection (sertit.u-strasbg.fr) pour nous avoir fourni les données, ainsi que l'Institut Carnot (www.instituts-carnot.eu) et la Région Alsace pour le financement de la thèse.

comme le vert, afin de rendre plus intuitive l'interprétation par un humain [16]. Ils peuvent être calculés sans avoir de données en proche infrarouge qui n'est pas disponible pour les images RVB. Les références [16, 32] comparent et discutent ces différents indices.

L'inconvénient des approches actuelles est qu'elles ne permettent pas de détecter simultanément les ombres et la végétation [20, 29]. Ainsi, par exemple, un pixel de végétation ombragée sera classé comme étant de la végétation par l'algorithme de détection de végétation et comme une ombre par l'algorithme de détection de l'ombre. Une inspection visuelle aboutira au même problème car l'information du pixel est imprécise et incertaine. Nous proposons dans cet article une méthode simple pour détecter simultanément les zones d'ombres et de végétation. En d'autres termes, nous proposons une méthode de segmentation des images en trois classes : « ombre », « végétation » et « autre ». Les indices d'ombre et de végétation décrits ci-dessus permettent de calculer des « images caractéristiques » et constituent les données utilisées par notre approche. La théorie de l'évidence de Dempster-Shafer (DS) [10, 28] sera ensuite utilisée pour fusionner les images caractéristiques en une carte de segmentation. Le principal avantage de cette théorie est sa capacité à prendre en compte l'ignorance de l'information en affectant un degré de confiance (la fonction de masse) aux différentes classes et à leur combinaison. Cependant, comme cette méthode fonctionne au niveau du pixel, indépendamment des pixels voisins, elle ne permet pas de tenir compte des dépendances spatiales et reste donc très sensible au bruit. Pour cette raison, nous supposons la markovianité du champ segmenté [6] pour mieux gérer la forte corrélation spatiale générique dans les images.

Notre travail apporte trois contributions. Premièrement, il introduit un nouveau schéma pour détecter simultanément les zones d'ombre et de végétation. Deuxièmement, l'utilisation de la théorie DS permet de combiner différents indices d'ombre et de végétation afin d'obtenir une segmentation plus fiable et plus précise. Troisièmement, la modélisation par champ de Markov permet d'exploiter les informations géométriques de l'image ; cette idée est largement utilisée en segmentation d'image, mais rarement dans le contexte de la détection de l'ombre et de la végétation.

Dans la section 2, nous introduisons les indices d'ombre et de végétation utilisés par notre approche. L'application de la théorie de DS à la détection de l'ombre et de la végétation est décrite dans la section 3. Nous y décrivons également la combinaison du modèle markovien avec la fusion DS. Enfin, les résultats expérimentaux sont présentés dans la section 4.

## 2 Modèles photométriques invariants à la couleur

Nous faisons les hypothèses courantes en détection de l'ombre, décrites dans [1] et nous avons testé les indices d'ombre proposées dans [2, 7, 8, 9, 14, 27, 30]. Nous ob-

tenons les meilleurs résultats avec l'indice  $c_3$  de l'espace de couleur  $c_1c_2c_3$ . Il a d'ailleurs été utilisé avec succès dans [2, 26]. Cet indice est défini par :

$$c_3 = \arctan \left( \frac{B}{\max(R, V)} \right) \quad (1)$$

où R, V et B représentent respectivement les composantes rouge, verte et bleue de l'image. L'un des inconvénients de cet indice est son instabilité pour certaines couleurs qui conduit à classer des pixels non ombragés comme des pixels ombragés (faux positifs) [2, 26]. Aussi, nous proposons de combiner l'indice  $c_3$  avec la luminance L (de l'espace de couleur HSL), comme cela est proposé dans [33], même si la luminance L détecte les zones d'ombre *et* de végétation.

En ce qui concerne la détection de la végétation, l'indice ExG est très performant [16]. Il est défini par [32] et nous le retiendrons dans la suite :

$$\text{ExG} = \frac{2 \times V - R - B}{R + V + B}. \quad (2)$$

## 3 Approche proposée

### 3.1 Concepts de base de la théorie des fonctions de croyance de Dempster-Shafer

La théorie de Dempster-Shafer (DS) est une théorie mathématique de l'évidence. Elle a été développée par A.P. Dempster [10] et G. Shafer [28]. Cette théorie suppose connu au départ un ensemble  $\Theta$  appelé cadre de discernement et contenant  $K$  éléments  $\{H_i\}, 1 \leq i \leq K$ , exclusifs et exhaustifs. À partir de ce cadre de discernement, on construit un ensemble noté  $2^\Theta$ , comprenant les  $2^K$  propositions  $A$  de  $\Theta$  :

$$2^\Theta = \{A/A \subseteq \Theta\}$$

Une masse élémentaire  $m(\cdot)$  est une application de  $2^\Theta$  dans  $[0, 1]$  vérifiant les trois propriétés suivantes :

$$0 \leq m(A) \leq 1, \quad \sum_{A \in 2^\Theta} m(A) = 1, \quad m(\emptyset) = 0$$

Deux fonctions dérivées des masses de croyances, appelées plausibilité (Pls) et crédibilité (Bel), s'obtiennent de la manière suivante :

$$\forall B \subseteq \Theta; \text{Pls}(A) = \sum_{B \cap A \neq \emptyset} m(B); \quad \text{Bel}(A) = \sum_{B \subseteq A} m(B)$$

Ces mesures peuvent être vues comme des bornes inférieure et supérieure de la fonction de masse  $m$ .

Supposons que l'on dispose de deux sources  $S_1, S_2$ . Les fonctions de masses  $m_1(\cdot)$  et  $m_2(\cdot)$  associées à chacune de ces sources peuvent être combinées de manière à fournir une fonction de masse résultante  $m$  qui synthétise la

connaissance apportée par les deux sources. Cette combinaison s'effectue de la manière suivante :

$$m_{1,2}(A) = m_1(A) \oplus m_2(A) \\ = \frac{1}{1 - \mathcal{K}} \sum_{B_1 \cap B_2 = A \neq \emptyset} m_1(B_1).m_2(B_2) \quad (3)$$

où  $\oplus$  représente la somme de la règle de combinaison de Dempster [10]. L'inconsistance de la fusion  $\mathcal{K}$  est calculée par :

$$\mathcal{K} = \sum_{B_1 \cap B_2 = \emptyset} m_1(B_1).m_2(B_2) \quad (4)$$

### 3.2 Utilisation de la théorie DS pour la détection de l'ombre et de la végétation

À partir de la représentation RVB des pixels de l'image, les indices  $c_3$ , ExG et L permettent de calculer respectivement les images caractéristiques  $Y_1$ ,  $Y_2$  et  $Y_3$ . Ces images caractéristiques sont les entrées de notre approche qui calcule une carte de segmentation  $X$  à valeurs dans  $\Omega = \{\omega_1, \omega_2, \omega_3\}$ , où  $\omega_1 = \text{« ombre »}$ ,  $\omega_2 = \text{« végétation »}$  et  $\omega_3 = \text{« autre »}$ .

Un seuillage automatique de Otsu [19] est appliqué aux images  $Y_1$ ,  $Y_2$  et  $Y_3$  afin d'obtenir une segmentation initiale des zones d'ombre, des zones de végétation et des zones sombres (qui inclut les zones d'ombre et de végétation). La méthode de Otsu est d'ailleurs très utilisée pour détecter l'ombre [8, 14] pour la qualité de ses résultats. Ainsi, l'image  $Y_1$  est segmentée en deux classes  $\omega_1$  et  $\{\omega_2, \omega_3\}$ . De même,  $Y_2$  est segmentée en les classes  $\omega_2$  et  $\{\omega_1, \omega_3\}$  et  $Y_3$  en les classes  $\omega_3$  et  $\{\omega_1, \omega_2\}$ . La théorie DS appliquée à la segmentation d'image permet alors de fusionner un par un les pixels provenant des trois segmentations et d'inférer sur les hypothèses (simples)  $H_i$  représentant les groupes simples :  $H_i = \{\omega_i\}$ . On note  $A_i$  une hypothèse simple ou une union d'hypothèses simples. Le cadre de discernement  $\Theta$  regroupe l'ensemble des classes :  $\Theta = \{\{\omega_1\}, \{\omega_2\}, \{\omega_3\}\}$ . On définit également des fonctions de masse en s'appuyant sur l'hypothèse de distributions gaussiennes [3]. La fonction de masse pour  $Y_1$ , définie sur  $\{\emptyset, A_1 = \{\omega_1\}, A_2 = \{\{\omega_2\}, \{\omega_3\}\}, \Theta\}$  est donc :

$$m_1(A_i) = \frac{1}{\sigma_{1i} \sqrt{2\pi}} \exp\left(-\frac{(y_{1s} - \mu_{1i})^2}{2\sigma_{1i}^2}\right) \quad (5)$$

où  $i \in \{1, 2\}$ ,  $y_{1s}$  est la valeur du pixel  $s$  de l'image  $Y_1$ ,  $\mu_{1i}$  (resp.  $\sigma_{1i}^2$ ) est la moyenne (resp. la variance) des pixels sous l'hypothèse  $A_i$  pour  $Y_1$ . Les quantités  $\mu_{1i}$  et  $\sigma_{1i}^2$  sont estimées par :

$$\mu_{1i} = \frac{1}{|A_i|} \sum_{s \in A_i} y_{1s} \quad (6)$$

$$\sigma_{1i}^2 = \frac{1}{|A_i| - 1} \sum_{s \in A_i} (y_{1s} - \mu_{1i})^2 \quad (7)$$

où  $|A_i|$  est le nombre de pixels sous l'hypothèse  $A_i$ .

L'intérêt de la théorie DS réside dans la représentation de l'incertitude au moyen de la croyance sur le cadre de discernement  $\Theta$ . Cela permet de définir  $m_1(\Theta) = (1 - m_1(A_1)) \times (1 - m_1(A_2))$ . Les fonctions de masse sont ensuite normalisées pour que leur somme soit égale à 1. Les fonctions de masse pour les images  $Y_2$  et  $Y_3$ , définies respectivement sur  $\{\emptyset, \{\omega_2\}, \{\{\omega_1\}, \{\omega_3\}\}, \Theta\}$  et  $\{\emptyset, \{\omega_3\}, \{\{\omega_1\}, \{\omega_2\}\}, \Theta\}$ , sont estimées de la même manière. Les fonctions de masse des trois images étant estimées, leur combinaison est réalisée en utilisant la somme orthogonale  $m = m_1 \oplus m_2 \oplus m_3$ .

Dans le contexte de la classification, la décision consiste à choisir parmi la plausibilité maximale, la croyance maximale ou la probabilité pignistique [10] comme l'hypothèse la plus probable  $H_i$ . La prise de décision est effectuée sur les hypothèses simples  $H_i$ .

### 3.3 Champ de Markov

La fusion des informations à l'aide de la théorie de DS travaille au niveau de pixel : cela suppose implicitement que chaque pixel de l'image ne dépendrait pas de ses voisins, ce qui implique que la procédure resterait très sensible au bruit. Nous allons donc utiliser un modèle de champ de Markov [13], souvent utilisé pour introduire de la dépendance spatiale. Cette hypothèse permet de déterminer la classe de chaque pixel en prenant en compte les classes des pixels proches, et éventuellement d'introduire une modélisation floue [25].

Soit  $X$  un champ aléatoire sur l'ensemble  $\mathcal{S}$  des pixels, à valeurs dans un ensemble fini de classes  $\Omega = \{\omega_1, \dots, \omega_K\}$ . On note  $x$  une réalisation de  $X$  et  $x_s$  la valeur de  $x$  au pixel  $s \in \mathcal{S}$ . Par définition,  $X$  est un champ de Markov si et seulement si

$$p(X_s = x_s | X_{\mathcal{S} - \{s\}} = x_{\mathcal{S} - \{s\}}) = p(X_s = x_s | X_{\mathcal{V}_s} = x_{\mathcal{V}_s}) \quad (8)$$

où  $x_{\mathcal{S} - \{s\}}$  est l'ensemble des pixels de la réalisation à l'exception du pixel  $s$  et  $\mathcal{V}_s$  représente l'ensemble des sites voisins de  $s$ . À partir des observations  $\mathbf{Y} = (Y_1, \dots, Y_m)$ , la carte de segmentation  $X$  peut être obtenue en calculant l'estimation du maximum a posteriori (MAP) de  $X$  [21] :

$$\hat{x}_{\text{MAP}} = \arg \max_x p(X = x | \mathbf{Y} = \mathbf{y}). \quad (9)$$

L'optimisation est effectuée à l'aide de l'algorithme ICM (*Iterative Conditional Modes*) [6]. La loi a posteriori conditionnelle de  $\hat{x}_s$  s'écrit :

$$p(X_s = x_s | \mathbf{Y} = \mathbf{y}, X_{\mathcal{S} - \{s\}} = \hat{x}_{\mathcal{S} - \{s\}}) \\ \propto p(\mathbf{Y}_s = \mathbf{y}_s | X_s = x_s) \times p(X_s = x_s | \mathbf{X}_{\mathcal{V}_s} = \hat{\mathbf{x}}_{\mathcal{V}_s}) \quad (10)$$

Dans notre implémentation, nous considérons un voisinage du second ordre (8-connexité) [13].

### 3.4 Théorie DS dans un contexte markovien

Au cours des dernières années, la théorie DS et les champs de Markov ont été utilisés dans des méthodes de classification, souvent dans le cas d'observations multisources [4, 5,

12, 22]. Le cadre probabiliste attribue une vraisemblance  $p(\mathbf{Y}_s = \mathbf{y}_s | X_s = x_s)$  uniquement aux classes  $\omega_k \in \Omega$ . En revanche, la théorie DS remplace cette vraisemblance par une fonction de masse sur  $\{\omega_k\}$ . Dans la suite de l'article, l'hypothèse simple du pixel  $s$  est noté  $H_{x_s}$ . Dans [5], les auteurs proposent de remplacer la vraisemblance de l'équation (10) par la fonction de plausibilité afin de prendre en compte les informations contenues dans les hypothèses simples comme multiples :

$$p(\mathbf{Y}_s = \mathbf{y}_s | X_s = x_s) \equiv \text{Pls}_s(H_{x_s}) = \sum_{A_i \cap H_{x_s} \neq \emptyset} m_s(A_i). \quad (11)$$

Par ailleurs, afin de gérer les hypothèses multiples  $A_i \subset \Theta$ , l'a priori conditionnel de l'équation (10) peut être remplacé par :

$$p(X_s = x_s | \mathbf{X}_{\mathcal{V}_s} = \hat{x}_{\mathcal{V}_s}) \equiv m_s(A_i | \hat{x}_{\mathcal{V}_s}) = \frac{\exp \left( - \sum_{H_k \cap A_i \neq \emptyset} \beta \sum_{l \in \mathcal{V}_s} \delta(k - \hat{x}_l) \right)}{\sum_{A_i \in 2^\Omega} \exp \left( - \sum_{H_k \cap A_i \neq \emptyset} \beta \sum_{l \in \mathcal{V}_s} \delta(k - \hat{x}_l) \right)} \quad (12)$$

où  $\beta$  est un paramètre du modèle markovien et  $\delta(\cdot)$  représente la fonction de Kronecker définie par

$$\delta(x_s - x_l) = \begin{cases} 1 & \text{si } x_s = x_l \\ 0 & \text{sinon.} \end{cases} \quad (13)$$

Le paramètre  $\beta$  est estimé par [11]. Enfin, l'a posteriori de l'équation (10) peut être remplacé par  $M_s(\cdot)$  qui porte l'information jointe. Celle-ci est obtenue avec la règle de combinaison de Dempster :

$$M_s(A_i) = \frac{1}{1 - \mathcal{K}} \sum_{A_p \cap A_q = A_i} m_s(A_p) m_s(A_q | \hat{x}_{\mathcal{V}_s}) \quad (14)$$

où

$$\mathcal{K} = \sum_{A_p \cap A_q = \emptyset} m_s(A_p) m_s(A_q | \hat{x}_{\mathcal{V}_s}). \quad (15)$$

Une fois que toutes les fonctions de masse des hypothèses simples et multiples d'un pixel  $s$  sont déterminées, plusieurs approches peuvent être choisies pour estimer  $\hat{x}_s$ . Nous avons décidé ici de maximiser la fonction de plausibilité sur l'information jointe :

$$\hat{x}_s = \arg \max_{x_s} \left( \sum_{A_i \cap H_{x_s} \neq \emptyset} M_s(A_i) \right). \quad (16)$$

## 4 Résultats expérimentaux

L'approche proposée détermine, à partir des images caractéristiques issues des indices  $c_3$ , ExG et L, une carte de segmentation  $X$  avec sur trois classes (« ombre », « végétation », « autre »). L'initialisation correspond à un seuillage

d'Otsu [19] suivi d'une fusion à l'aide de la théorie DS ; elle constitue la méthode appelée THDS dans la suite. Après plusieurs itérations de l'ICM, on obtient la segmentation finale. Dans cette section, nous comparons la méthode proposée avec trois autres approches : un seuillage de Otsu pour détecter uniquement l'ombre (DO), un seuillage de Otsu pour détecter uniquement la végétation (DV) et la méthode THDS.

Les données sont fournies par le Service régional de traitement d'image et de télédétection (sertit.u-strasbg.fr) dans le cadre du projet Kal-Haïti. Deux résultats d'expériences comparatives sont représentés dans les figure 1 et 2. La figure 1 représente une zone urbaine avec une forte densité de bâtiments impliquant de nombreuses ombres portées. On constate que les zones d'ombre sont obtenues avec une grande précision grâce à la modélisation markovienne de l'information spatiale (cercle rouge) : les petites zones isolées de végétation sont supprimées et la forme de l'ombre est préservée. La figure 2 représente une zone peu urbanisée contenant beaucoup de végétation ainsi que de l'eau (piscine). Comme les zones construites et le sol possèdent à peu près le même indice  $c_3$  que les zones d'ombre, elles sont classées comme telles dans la figure 2-(c). Pour une raison similaire, l'eau est considérée à tort comme de la végétation dans la figure 2-(d) (cercle rouge). L'utilisation de la luminance L permet de corriger ces erreurs : les bâtiments, le sol et l'eau ne sont pas considérées comme des zones sombres dans la figure 2-(e). On observe que la méthode proposée (figure 1-(g) et figure 2-(g)) donne le résultat le plus proche de la segmentation manuelle considérée comme la vérité terrain (figure 1-(b) et figure 2-(b)) : elle résout les mauvaises classifications et améliore la précision de la segmentation. Sans modélisation markovienne, on obtient une segmentation très parcellisée (figure 1-(f) et figure 2-(f)).

Les tableaux 1 et 2 résument la qualité de la segmentation des quatre méthodes pour les deux exemples illustrés dans les figures 1 et 2. Nous utilisons les mêmes indices de performance qui sont définies dans [23]. L'évaluation est effectuée en calculant le taux de vrais positifs (VP), faux négatifs (FN), faux positifs (FP) et vrai négatifs (VN). En ce qui concerne les ombres, VP est le nombre de pixels ombrés correctement identifiés, FN est le nombre de pixels ombrés considérés comme non ombragés, FP est le nombre de pixels non ombrés considérés comme étant de l'ombre et VN est le nombre de pixels non ombrés correctement identifiés. Ces paramètres sont définis de la même manière pour la détection de la végétation. La somme VP + FN + FP + VN correspond donc au nombre total de pixels dans l'image. La précision du photointerpréteur indique comment les pixels des catégories connues sont correctement classés. La précision de l'utilisateur indique la probabilité de pixels correctement classés par rapport à la référence qui est ici le photointerpréteur. En combinant ces indices de précision, on obtient la précision générale  $\tau$  qui permet d'évaluer la performance de l'algorithme. Des valeurs de



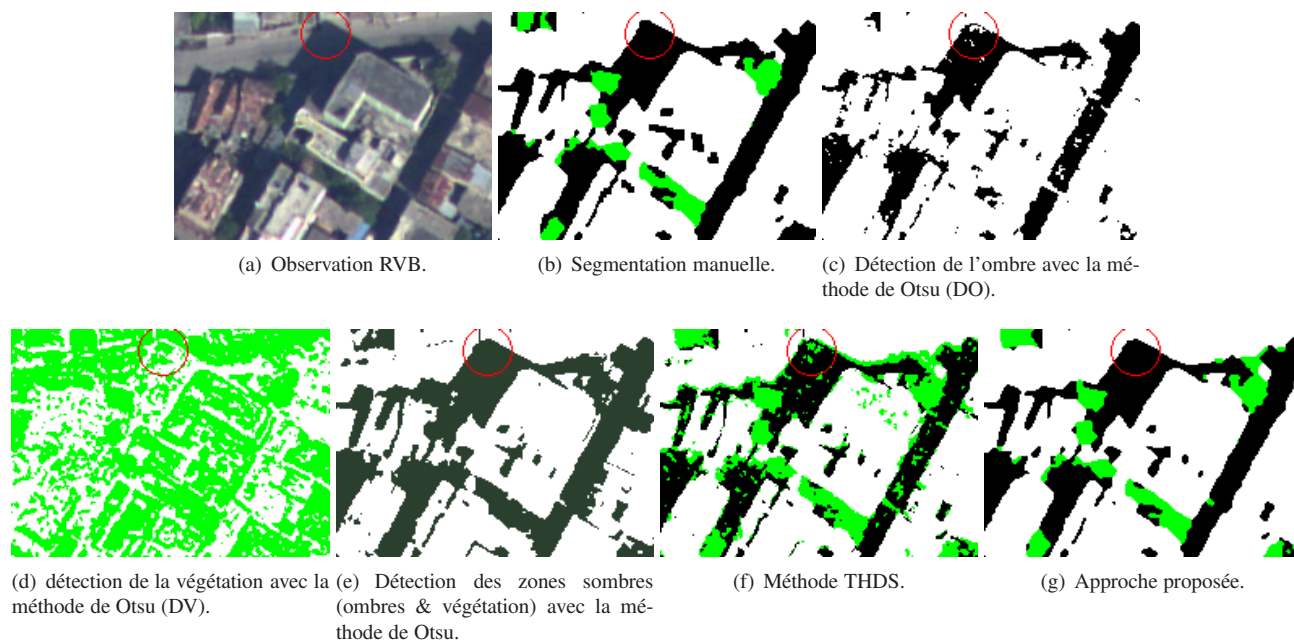


FIGURE 1 – Segmentation des ombres (en noir), de la végétation (en vert) et du reste (en blanc) d'une zone urbaine.




FIGURE 2 – Segmentation des ombres (en noir), de la végétation (en vert) et du reste (en blanc) d'une zone de banlieue.

Méthode	Détection des ombres					Détection de la végétation				
	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale $\tau$	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale $\tau$
	Ombre	Non-ombre	Ombre	Non-ombre		Végétation	Non-végétation	Végétation	Non-végétation	
DO	79.59	99.60	98.80	92.18	93.74	nc	nc	nc	nc	nc
DV	nc	nc	nc	nc	nc	94.17	43.57	10.20	99.09	46.80
Méthode THDS	82.88	98.67	96.28	93.30	94.05	96.68	90.84	41.83	99.75	91.21
Méthode proposée	92.35	99.93	99.82	96.93	<b>97.71</b>	99.25	98.37	80.60	99.94	<b>98.42</b>

TABLE 1 – Qualité de la segmentation pour l'image représentée dans la figure 1. Les valeurs sont données en pourcentage.

Méthode	Détection des ombres					Détection de la végétation				
	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale $\tau$	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale $\tau$
	Ombre	Non-ombre	Ombre	Non-ombre		Végétation	Non-végétation	Végétation	Non-végétation	
DO	84.86	46.76	28.35	92.56	54.33	nc	nc	nc	nc	nc
DV	nc	nc	nc	nc	nc	78.06	96.25	93.24	86.89	89.01
Méthode THDS	91.86	87.93	65.41	97.75	88.72	85.78	97.70	96.11	91.21	92.95
Méthode proposée	96.68	98.43	93.87	99.17	<b>98.08</b>	96.44	99.31	98.93	97.68	<b>98.16</b>

TABLE 2 – Qualité de la segmentation pour l'image représentée dans la figure 2. Les valeurs sont données en pourcentage.

paramètres élevées correspondent à de bons résultats. On conclut que l'approche proposée donne de très bons résultats comme l'illustre les figures 1 et 2 et les tableaux 1 et 2.

## 5 Conclusion

Cet article présente une nouvelle stratégie de détection simultanée de l'ombre et de la végétation dans des images aériennes. Trois indices d'ombre et de végétation ( $c_3$ , ExG et L) sont proposés pour obtenir trois images segmentées, lesquelles sont fusionnées en utilisant la théorie de DS : l'intérêt est de gérer l'imprécision et l'incertitude des images segmentées. Un champ de Markov permet de prendre en compte la corrélation spatiale entre pixels. Finalement, l'approche fournit une carte de segmentation en trois classes (ombre, végétation, autre) et les résultats expérimentaux montrent qu'elle s'avère suffisamment fiable pour une interprétation humaine.

## Références

- [1] K.R.M. Adeline, M. Chen, X. Briottet, S.K. Pang, and N. Paparoditis. Shadow detection in very high spatial resolution aerial images : A comparative study. *ISPRS Journal of Photogrammetry and Remote Sensing*, 80 :21–38, 2013.
- [2] V. Arévalo, J. González, and G. Ambrosio. Shadow detection in colour high-resolution satellite images. *International Journal of Remote Sensing*, 29(7) :1945–1963, 2008.
- [3] Salim Ben Chaabane, M. Sayadi, F. Fnaiech, and E. Brasart. Color image segmentation using automatic thresholding and the fuzzy c-means techniques. In *IEEE Mediterranean Electrotechnical Conference, MELECON'2008, Ajaccio-France*, pages 857–861, 2008.
- [4] A. Bendjebbour, Y. Delignon, L. Fouque, V. Samson, and W. Pieczynski. Multisensor image segmentation using Dempster-Shafer fusion in Markov fields context. *IEEE Transactions on Geoscience and Remote Sensing*, 39(8) :1789–1798, 2001.
- [5] L. Bentabet and J. Maodong. A combined markovian and dirichlet sub-mixture modeling for evidence assignment : Application to image fusion. *Pattern Recognition Letters*, 29(13) :1775–1783, 2008.
- [6] J. Besag. On the statistical analysis of dirty picture. *Journal of the Royal Statistical Society*, 48(3) :259–302, 1986.
- [7] Chun-Ting Chen, Chung-Yen Su, and Wen-Chung Kao. An enhanced segmentation on vision-based shadow removal for vehicle detection. In *International Conference on Green Circuits and Systems*, pages 679–682, 2010.
- [8] Kuo-liang Chung, Yi-ru Lin, and Yong-huai Huang. Efficient shadow detection of color aerial images based on successive thresholding scheme. *IEEE Transactions on Geoscience and Remote Sensing*, 47(2) :671–682, February 2009.
- [9] R. Cucchiara, C. Grana, M. Piccardi, and A. Prati. Detecting moving objects, ghosts, and shadows in video streams. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 25(10) :1337–1342, 2003.
- [10] Arthur P Dempster. A generalization of Bayesian inference. *Journal of the Royal Statistical Society. Series B (Methodological)*, pages 205–247, 1968.
- [11] H. Derin and H. Elliott. Modeling and segmentation of noisy and textured images using gibbs random fields. *IEEE Transactions on pattern analysis and machine intelligence*, (1) :39–55, 1987.
- [12] Samuel Foucher, Mickaël Germain, and Jean-Marc Boucher. Multisource classification using ICM and Dempster-Shafer theory. *IEEE Transactions on Instrumentation and Measurement*, 51(2) :277–281, 2002.
- [13] S Geman and D Geman. Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 6(6) :721–41, 1984.
- [14] Victor J.D.Tsai. A comparative study on shadow compensation of color aerial images in invariant color models.

- IEEE Transactions on Geoscience and Remote Sensing*, 44(6) :1661–1671, June 2006.
- [15] T. Kataoka, T. Kaneko, H. Okamoto, and S. Hata. Crop growth estimation system using machine vision. In *Proceedings of the 2003 IEEE/ASME International Conference on Advanced Intelligent Mechatronics*, pages 1079–1083, 2003.
  - [16] George E. Meyer and João Camargo Neto. Verification of color vegetation indices for automated crop imaging applications. *Computers and Electronics in Agriculture*, 63(2) :282–293, October 2008.
  - [17] Airtton M. Polidório. Automatic shadow segmentation in aerial color images. *Computer Graphics and Image Processing, 2003. SIBGRAPI 2003. XVI Brazilian Symposium*, pages 270–277, 2003.
  - [18] J.C. Neto, G.E. Meyer, and D.D. Jones. Individual leaf extractions from young canopy images using Gustafson–kessel clustering and a genetic algorithm. *Computers and Electronics in Agriculture*, 51 :66–85, 2006.
  - [19] N. Otsu. A threshold selection method from gray-level histograms. *Automatica*, 11(285-296) :23–27, 1975.
  - [20] Ali Ozgun Ok. Automated detection of buildings from single vhr multispectral images using shadow information and graph cuts. *ISPRS Journal of Photogrammetry and Remote Sensing*, 86 :21–40, December 2013.
  - [21] W. Pieczynski. Modèles de Markov en traitements d’images Markov models in image processing. *Traitement du Signal*, 20(3) :255–278, 2003.
  - [22] W. Pieczynski and D. Benboudjema. Multisensor triplet markov fields and theory of evidence. *Image and Vision Computing*, 24(1) :61–69, 2006.
  - [23] A. Prati, I. Mikic, M.M. Trivedi, and R. Cucchiara. Detecting moving shadows : algorithms and evaluation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 25(7) :918–923, July 2003.
  - [24] JW Rouse, RH Haas, JA Schell, DW Deering, and JC Harlan. *Monitoring the vernal advancement and retrogradation (greenwave effect) of natural vegetation*. Texas A & M University, Remote Sensing Center, 1974.
  - [25] S. Ruan, B. Moretti, J. Fadili, and D. Bloyet. Fuzzy markovian segmentation in application of magnetic resonance images. *Computer Vision and Image Understanding*, 85(1) :54–69, 2002.
  - [26] E. Salvador, A. Cavallaro, and T. Ebrahimi. Shadow identification and classification using invariant color models. In *IEEE International Conference on Acoustics, Speech, and Signal Processing*, volume 3, pages 1545–1548. IEEE, 2001.
  - [27] E. Salvador, A. Cavallaro, and T. Ebrahimi. Cast shadow segmentation using invariant color features. *Computer Vision and Image Understanding*, 95(2) :238–259, August 2004.
  - [28] Glenn Shafer. *A mathematical theory of evidence*, volume 1. Princeton university press Princeton, 1976.
  - [29] N. Shorter and T. Kasparis. Automatic vegetation identification and building detection from a single nadir aerial image. *Remote Sensing*, 1(4) :731–757, October 2009.
  - [30] B. Sun and S. Li. Moving cast shadow detection of vehicle using combined color models. In *Chinese Conference on Pattern Recognition*, pages 1–5, 2010.
  - [31] Compton J Tucker. Red and photographic infrared linear combinations for monitoring vegetation. *Remote sensing of Environment*, 8(2) :127–150, 1979.
  - [32] D. M. Woebbecke, G. E. Meyer, K. Von Bargen, and D. A. Mortensen. Color indices for weed identification under various soil, residue, and lighting conditions. *Transactions of the ASAE*, 38(1) :259–269, 1995.
  - [33] J. Yao and Zhongfei (Mark) Zhang. Hierarchical shadow detection for color aerial images. *Computer Vision and Image Understanding*, 102(1) :60–69, 2006.