

Détection simultanée de l'ombre et la végétation sur des images aériennes couleur en haute résolution

Tran-Thanh Ngo¹, Christophe Collet¹, Vincent Mazet¹

ICube, Université de Strasbourg - CNRS
300 Bd Sébastien Brant, CS 10413, F-67412 Illkirch cedex, FRANCE
{tngo,c.collet,vincent.mazet}@unistra.fr

RÉSUMÉ. Nous proposons une nouvelle méthode pour détecter simultanément les zones d'ombre et de végétation dans des images de télédétection. Plusieurs indices d'ombre et de végétation sont fusionnés grâce à la théorie de Dempster-Shafer (DS) afin d'augmenter la fiabilité et la précision de la segmentation. La fusion de DS étant une méthode pixellique, elle est incorporée dans un contexte markovien pour obtenir une segmentation régularisée et plus optimale. Les évaluations sur des images aériennes montrent clairement que cette méthode est robuste et précise.

ABSTRACT. We propose a new method to simultaneously detect shadows and vegetation in remote sensing images. Several shadow and vegetation indices are merged with the Dempster-Shafer (DS) theory so as to increase the reliability and accuracy of the segmentation. The per-pixel DS fusion is incorporated in a Markovian context to obtain an optimal and regularized segmentation result. Evaluation on aerial images clearly shows that this new method is robust and accurate.

MOTS-CLÉS : Télédétection, Dempster-Shafer, champs de Markov cachés, détection d'ombre, détection de végétation, segmentation multivariée.

KEYWORDS: Remote sensing, Dempster-Shafer, Markov random field, shadow detection, vegetation detection, multivariate segmentation.

DOI:10.3166/TS..2-26 © 2015 Lavoisier

Extended Abstract

Introduction

In recent years, the effects of natural catastrophes and human activities have emphasized the need for developing a broader view of the Earth. According to cartographic experts, shadow and vegetation can provide additional geometric and semantic clues about the state of buildings after natural catastrophes. This work is devoted to

simultaneous shadow/vegetation detection. Since the shape features of buildings are extracted from this detection, correctness and precision of the segmentation are strongly required.

Current shadow/vegetation detection methods in the literature detect separately shadow regions and vegetation regions (Ozgun Ok, 2013 ; Shorter, Kasparis, 2009). The drawback of these methods is that, for example, a vegetated pixel covered by shadow can be classified as vegetation (by a vegetation detection algorithm), and at the same time as shadow (by a shadow detection algorithm). Thus, these methods can not provide a sufficiently good segmentation map. In fact, visual inspection also has a similar problem since the pixel information is imprecise and uncertain. In this paper, we propose a new method of simultaneously detecting shadow regions and vegetation regions, in other words, segmenting images into three classes : « shadow », « vegetation » and « other ». This approach differs from what can be found in the literature in three distinct aspects: firstly, it introduces a new scheme to *simultaneously* detect shadow regions and vegetation regions. Secondly, the use of DS theory allows us to combine different shadow indices and vegetation indices in order to increase the information quality and to obtain a more reliable and accurate shadow/vegetation detection. Thirdly, we exploit image geometric information by using a Markov random field, that is often used in image segmentation but rarely in the shadow/vegetation detection case.

Model and Algorithm

Given the (R,G,B) color representation of a pixel, three different indices are computed with the following equations:

$$c_3 = \arctan\left(\frac{B}{\max(R, G)}\right), \quad L = \frac{R + G + B}{3}, \quad \text{ExG} = \frac{2 \times G - R - B}{R + G + B}$$

c_3 is used to detect shadow regions (Arévalo *et al.*, 2008 ; Salvador *et al.*, 2001). Because of the instability of indice c_3 for certain color values that lead to the misclassification of non-shadow pixels as shadow (false positives), we use luminance L (HSL color space). This indice allows to detect dark regions (that may include shadow regions and vegetation regions). Among different vegetation indices presented in (Meyer, Neto, 2008), of remarkable effectiveness is ExG, that is used in our model to detect vegetation regions. It should be noted that none of these indices allows to segment image into three classes : « shadow », « vegetation » and « other ».

We use c_3 to build $Y^{(1)}$, ExG to build $Y^{(2)}$, L to build $Y^{(3)}$. Let us denote $\omega_1, \omega_2, \omega_3$, three clusters representing respectively “shadow”, “vegetation” and “other”. Our algorithm takes three feature images $Y^{(1)}, Y^{(2)}, Y^{(3)}$ as the input, and the output is a segmented image \mathbf{x} , where values of \mathbf{x} are in $\Omega = \{\omega_1, \omega_2, \omega_3\}$. Each feature image is considered as an information source. In this context, Dempster-Shafer (DS) fusion (Dempster, 1968 ; Shafer, 1976) that aims at merging different data sources is employed. Firstly, the automatic thresholding technique proposed by Otsu

(Otsu, 1975) is applied over the images $Y^{(1)}, Y^{(2)}, Y^{(3)}$ for determining the optimal threshold to segment each feature image into 2 classes. Secondly, the mass functions are estimated by the assumption of Gaussian distribution. Then, they are combined through the DS combination rule. Final image segmentation is achieved using a DS decision strategy. This decision consists of choosing the hypothesis giving the maximum belief or plausibility value calculated from the fused mass functions.

Since the DS fusion processes at a pixel-level, it is very sensitive to noise. The next stage concerns the combination of the DS fusion and Markov random field model to exploit spatial dependencies segmentation result. In recent years, both the MRF and DS theory of evidence have been incorporated into more general methods for scene classification, often involving multisource analysis (Bendjebbour *et al.*, 2001 ; Ben-tabet, Maodong, 2008). In fact, the probabilistic framework assigns likelihood values $p(\mathbf{y}_s|x_s)$ only for each class $\omega_i \in \Omega$. From the view of evidence theory, the likelihood can be assimilated to a mass function which charges the singleton $H_{x_s} = \{\omega_i\}$, where H_{x_s} denotes the simple hypothesis of pixel s . The regularization term of MRF model can be generalized to deal with the compound hypotheses. Considering this term and the likelihood as two “evidential” sources of information, the posterior probability can be replaced by their DS orthogonal sum. Once all of the mass functions of the single and compound hypotheses related to pixel s are determined, \hat{x}_s is estimated by maximizing the plausibility function.

Results and discussion

The functionality of each step in our proposed method is analyzed. By visual comparison, we observe that the proposed method solves the problems of false dismissals, and improves the accuracy of segmentation. The fusion corrects the misclassification of each feature, and the ICM removes the small objects in segmentation. The shape of shadow regions is precisely obtained since the image geometric information is exploited through MRF modelling (figure 3). Besides, we evaluate the proposed method both qualitatively and quantitatively, and compare it to the two state-of-the-art algorithms: the method of (Tian *et al.*, 2012) for shadow detection, and the method of (Shorter, Kasparis, 2009) for vegetation detection. The results shown in Table 3 and 4 demonstrates that our method has the best overall accuracy for both shadow detection and vegetation detection. We also extend this method for considering not only pure class (shadow or vegetation) but also mixed class (shadow and vegetation). The result shown in figure 7 is very promising.

1. Introduction

Les catastrophes naturelles ou l'impact de l'activité humaine sur l'environnement nécessitent une observation de la Terre toujours plus complète. Dans ce cadre, l'étude de l'ombre et de la végétation sur des images aériennes ou satellitaires permet d'obtenir des indices géométriques et sémantiques sur l'état des bâtiments après une catastrophe naturelle. Ce travail est consacré à la détection *simultanée* de

l'ombre et de la végétation sur des images aériennes RVB (rouge, vert, bleu) et en haute résolution (24 cm/pixel). Les images classifiées ainsi obtenues permettront ultérieurement d'extraire la forme des bâtiments ; il est donc important d'obtenir des cartes de segmentation précises sur le bâtiment avant et après la catastrophe.

L'ombre apparaît dans la scène lorsque l'objet est totalement ou partiellement caché de la lumière directe. Beaucoup de méthodes ont été proposées ces dernières années sur la détection d'ombre dans les images aériennes (Arévalo *et al.*, 2008 ; Chen *et al.*, 2010 ; Cucchiara *et al.*, 2003 ; Tsai, 2006 ; Salvador *et al.*, 2004 ; Sun, Li, 2010). (Salvador *et al.*, 2004) ont présenté des méthodes de détection d'ombre portée basées sur les propriétés géométriques et spectrales, en utilisant le fait que l'ombre portée assombrit et diminue fortement le contraste impactant ainsi c_3 dans l'espace de représentation colorimétrique $c_1c_2c_3$ (Gevers, Smeulders, 1999). En ce qui concerne les effets de dispersion atmosphérique, (Polidorio *et al.*, 2003) observe dans les zones d'ombre de fortes saturations et de faibles luminances. Il propose donc de seuiller la différence entre l'image de saturation et l'image d'intensité dans l'espace normalisé HSI. Reprenant le modèle d'illumination proposé par Phong (Phong, 1975), (Huang *et al.*, 2004) ont proposé un nouveau modèle seuillant séquentiellement la teinte, le canal bleu et la différence entre les canaux vert et bleu pour détecter les zones d'ombre. (Yao, Zhang, 2006) ont proposé une méthode de détection hiérarchique comportant deux étapes : une classification au niveau pixel (basée sur une modélisation par graphe utilisant l'algorithme EM), suivie d'une minimisation de l'erreur bayésienne. (Tsai, 2006) calcule, pour les espaces de couleurs HSV, HSI, HCV, YIQ et YCbCr, le rapport entre teinte et intensité. La méthode de seuillage d'Otsu (Otsu, 1975) est alors utilisée pour réaliser la segmentation. Néanmoins, cette approche tend à classer à tort le bleu sombre et le vert sombre en les considérant comme des zones d'ombre. Un article récent (Tian *et al.*, 2012) propose une alternative basée sur un modèle d'atténuation tri-bande (TAM). Ce modèle décrit les relations d'atténuation entre les ombres et le fond dans les trois canaux. Cette dernière méthode sera testée et comparée à la méthode que nous proposons.

De nombreuses approches existent pour mesurer la couverture végétale. Parmi elles, les méthodes de seuillage ont l'avantage de la simplicité tout en fournissant de bons résultats, par exemple : seuillage dynamique (Reid, Searcy, 1987), seuillage d'Otsu (Meyer, Neto, 2008), seuillage par hystérésis (Marchant *et al.*, 1998), seuillage qui maximise l'entropie (Aitkenhead *et al.*, 2003) (Tellaeche *et al.*, 2008). Pour cela, les recherches se sont orientées vers le calcul de différents types d'indices de végétation, comme par exemple le CIVE *color index of vegetation extraction* (Kataoka *et al.*, 2003), l'ExG *excess green index* (Woebbecke *et al.*, 1995), et l'ExGR *excess green minus excess red* (Neto *et al.*, 2006). En plus des méthodes de segmentation basées seuillage, on peut citer les approches utilisant les *mean-shift* (Zheng *et al.*, 2010) dans le contexte d'applications agricoles vidéo-surveillées afin de détecter la qualité des sols (Ponti, 2013), l'algorithme des c-moyennes floues a également été utilisé pour classer plantes, sols et régions résiduelles d'intérêt (Meyer *et al.*, 2004).

La détection séparée de l'ombre et de la végétation ne nous semble toutefois pas optimale. En effet, un pixel de végétation ombragée sera classé comme étant de la végétation par l'algorithme de détection de végétation et comme une ombre par l'algorithme de détection de l'ombre. Dès lors, l'utilisation des approches ci-avant n'est pas conseillée pour la détection simultanée de l'ombre et la végétation. Une inspection visuelle aboutira au même problème car l'information du pixel est imprécise et incertaine. Nous proposons dans cet article une méthode originale pour détecter simultanément les zones d'ombres et de végétation. En d'autres termes, nous proposons une méthode de segmentation des images en trois classes : « ombre », « végétation » et « autre ». Les indices d'ombre et de végétation décrits ci-avant permettent de calculer des « images caractéristiques » et constituent les données utilisées par notre approche. La théorie de l'évidence de Dempster-Shafer (DS) (Dempster, 1968 ; Shafer, 1976) sera ensuite utilisée pour fusionner les images caractéristiques en une carte de segmentation. Le principal avantage de cette théorie est sa capacité à prendre en compte l'ignorance de l'information en affectant un degré (ou masse) de connaissance non seulement aux différentes hypothèses définies séparément (hypothèse simples, ou singletons), mais aussi à l'ensemble des hypothèses (hypothèses composées). Cependant, comme cette méthode fonctionne ponctuellement, indépendamment des pixels voisins, elle ne permet pas de tenir compte des dépendances spatiales et reste donc très sensible au bruit. Pour cette raison, nous supposons la markovianité du champ segmenté (Besag, 1986) pour mieux gérer la forte corrélation spatiale générique dans les images.

Une illustration de ces étapes est donnée figure 3. Par simple comparaison visuelle, nous observons que la méthode proposée résout le problème de faux négatifs et améliore la précision de la segmentation. Nous évaluons la méthode proposée à la fois qualitativement mais aussi quantitativement, en comparant avec la méthode de (Tian *et al.*, 2012) pour la détection d'ombre et la méthode de (Shorter, Kasparis, 2009) pour la détection de végétation. Les résultats montrés dans les tables 3 et 4 montrent clairement que notre approche a les meilleures performances globales tant pour la détection d'ombre que pour la détection de végétation. Nous pouvons également étendre notre méthode pour considérer des classes de mélange (correspondant au mélange ombre-végétation) mais la quantification de ces résultats reste délicate (pas de vérité terrain disponible), même si le résultat montré en figure 7 paraît très prometteur pour discriminer les bâtiments détruits (leur ombre portée ne correspond pas à un mélange ombre-végétation).

Notre travail apporte trois contributions. Premièrement, il introduit un nouveau schéma pour détecter simultanément les zones d'ombre et de végétation. Deuxièmement, l'utilisation de la théorie DS permet de combiner différents indices d'ombre et de végétation afin d'obtenir une segmentation plus fiable et plus précise. Troisièmement, la modélisation par champ de Markov permet d'exploiter les informations de voisinage géométrique de l'image ; cette idée est largement utilisée en segmentation d'image, mais rarement dans le contexte de la détection de l'ombre et de la végétation.

Cet article est organisé de la manière suivante. Dans la section 2, nous introduisons les indices d'ombre et de végétation utilisés par notre approche. L'application de la théorie de DS à la détection de l'ombre et de la végétation est décrite dans la section 3. Nous y décrivons également la combinaison du modèle markovien avec la fusion DS. Les résultats expérimentaux sont présentés dans la section 4. La possibilité d'étendre notre méthode en considérant une classe mélange ombre-végétation est discutée en section 5. Enfin, la section 6 conclut cet article.

2. Modèles photométriques invariants à la couleur

Dans le contexte de l'imagerie aérienne, un état de l'art en détection d'ombre est présenté dans (Adeline *et al.*, 2013). Dans cet article, les approches sont regroupées en quatre grandes classes : les algorithmes basés propriétés, modèles, physique et apprentissage. Les avantages/inconvénients de ces approches sont présentés et illustrés sur des images réelles. Nous suivons les approches basées propriétés car elle ne requièrent pas d'information a priori, comme la géométrie 3D de la scène, les perturbations atmosphériques, etc. qui ne sont pas accessibles dans notre cas. Ces approches sont généralement basées sur le fait que les régions d'ombre deviennent plus sombres, mais conservent leur chrominance. Ainsi, des régions d'ombre peuvent être détectées en choisissant un espace colorimétrique avec une meilleure séparation entre la chrominance et l'intensité que l'espace RVB par exemple: HSV (Cucchiara *et al.*, 2003), $c_1c_2c_3$ (Salvador *et al.*, 2004), YUV (Chen *et al.*, 2010), RVB normalisé (Chen *et al.*, 2010), ou une combinaison d'entre eux (Sun, Li, 2010). D'autres auteurs exploitent le fait que les régions d'ombre ont une radiance décroissante sur le spectre des longueurs d'ondes courtes vers les longueurs d'ondes élevées en raison des phénomènes de dispersion (Adeline *et al.*, 2013).

À partir de ces hypothèses, différents indices ont été proposés pour quantifier l'ombre dans les images (Tsai, 2006 ; Polidorio *et al.*, 2003). Nous avons testé les indices d'ombre proposés et nous obtenons les meilleurs résultats avec l'indice c_3 de l'espace de couleur $c_1c_2c_3$. Il a d'ailleurs été utilisé avec succès dans (Arévalo *et al.*, 2008 ; Salvador *et al.*, 2001). Cet indice est défini par :

$$c_3 = \arctan \left(\frac{B}{\max(R, V)} \right) \quad (1)$$

où R, V et B représentent respectivement les composantes rouge, verte et bleue de l'image. L'un des inconvénients de cet indice est son instabilité pour certaines couleurs qui conduit à classer des pixels non ombragés comme des pixels ombragés (faux positifs) (Arévalo *et al.*, 2008 ; Salvador *et al.*, 2001). Aussi, nous proposons de combiner l'indice c_3 avec la luminance L (de l'espace de couleur HSL), comme cela est proposé dans (Yao, Zhang, 2006), même si la luminance L détecte les zones d'ombre et de végétation, parce que la végétation et l'ombre sont moins lumineuses que les autres zones. La luminance L est définie comme:

$$L = \frac{R + V + B}{3} \quad (2)$$

En ce qui concerne la détection de la végétation, il existe plusieurs indices pour estimer la densité de la végétation à partir d'images aériennes et satellitaires, largement utilisés depuis de nombreuses années. En plus du très populaire NDVI (*normalized difference vegetation index*) (Rouse, JW *et al.*, 1974 ; Tucker, Compton J, 1979), d'autres indices utilisant uniquement les bandes spectrales rouge, verte et bleue ont été proposées dans la littérature. Parmi eux, citons les indices CIVE (*color index of vegetation extraction*) (Kataoka *et al.*, 2003), ExG (*excess green index*) (Woebbecke *et al.*, 1995) et ExGR (*excess green minus excess red*) (Neto *et al.*, 2006). Ces indices permettent d'accentuer une couleur particulière comme le vert, afin de rendre plus intuitive l'interprétation par un humain (Meyer, Neto, 2008). Ils peuvent être calculés sans avoir de données en proche infrarouge qui n'est pas disponible pour les images RVB. Les références (Meyer, Neto, 2008 ; Woebbecke *et al.*, 1995) comparent et discutent ces différents indices. Nous avons testé ces indices pour notre base de données des images et nous constatons que l'indice ExG est le plus performant. Il est défini :

$$\text{ExG} = \frac{2 \times V - R - B}{R + V + B}. \quad (3)$$

3. Approche proposée

3.1. Concepts de base de la théorie des fonctions de croyance de Dempster-Shafer

La théorie de Dempster-Shafer (DS) est une théorie mathématique de l'évidence. Elle a été développée par A.P. Dempster (Dempster, 1968) et G. Shafer (Shafer, 1976). Cette théorie suppose connu un ensemble Θ appelé cadre de discernement et contenant K éléments $\{H_i\}, 1 \leq i \leq K$, exclusifs et exhaustifs. Une masse élémentaire $m(\cdot)$ est une application de 2^Θ dans $[0, 1]$ vérifiant les trois propriétés suivantes :

$$0 \leq m(A) \leq 1, \quad \sum_{A \subseteq \Theta} m(A) = 1, \quad m(\emptyset) = 0$$

Deux fonctions dérivées des masses de croyances, appelées plausibilité (Pls) et crédibilité (Bel), s'obtiennent de la manière suivante :

$$\forall B \subseteq \Theta; \text{Pls}(A) = \sum_{B \cap A \neq \emptyset} m(B); \quad \text{Bel}(A) = \sum_{B \subseteq A} m(B) \quad (4)$$

3.2. Utilisation de la théorie DS pour la détection de l'ombre et de la végétation

Étant donnée la représentation RVB d'un pixel, nous utilisons c_3 pour construire $Y^{(1)}$, ExG pour construire $Y^{(2)}$, L pour construire $Y^{(3)}$. Notons $\omega_1, \omega_2, \omega_3$ les trois classes représentant respectivement « ombre », « végétation » et « autre ». Notre algorithme est alimenté par les trois images caractéristiques $Y^{(1)}, Y^{(2)}, Y^{(3)}$ et produit une image classifiée \mathbf{x} . La valeur de \mathbf{x} au pixel s , notée x_s est à valeur dans $\Omega = \{\omega_1, \omega_2, \omega_3\}$.

On peut considérer chaque image caractéristique comme une source d'information. Dans ce contexte, la source $Y^{(1)}$ peut distinguer ω_1 des deux autres classes, mais pas ω_2 de ω_3 . La source $Y^{(2)}$ peut distinguer ω_2 des deux autres classes, mais pas ω_1 de ω_3 . De même la source $Y^{(3)}$ peut distinguer ω_3 des deux autres classes, mais pas ω_1 de ω_2 . Seule la fusion de ces trois sources permet de distinguer les 3 classes.

Les trois principales approches numériques pour la fusion de données sont la méthode probabiliste (Mohammad-Djafari, 1998), la théorie des ensembles flous (Hathaway *et al.*, 1996) et la théorie de l'évidence. La théorie des ensembles flous fournit beaucoup d'opérateurs de combinaison, qui permettent à l'utilisateur d'adapter la fusion à la spécificité des données mais ces opérateurs sont toujours choisis d'une façon supervisée. Pour l'inférence bayésienne, la limitation principale est qu'elle **ne peut pas** modéliser l'imprécision intrinsèque de la mesure (Boudraa *et al.*, 2004; Le Hegarat-Masclé *et al.*, 1997). La théorie DS permet de traiter l'ignorance et des informations manquantes en affectant un degré de confiance qui est appelé aussi fonction de masse à toutes les hypothèses. **De plus, un autre avantage majeure de la théorie de l'évidence est qu'elle permet de traiter non seulement les classes (l'hypothèse simple) mais aussi l'union de classes (l'hypothèse composée).**

Un seuillage automatique d'Otsu (Otsu, 1975) est appliqué aux images $Y^{(1)}$, $Y^{(2)}$ et $Y^{(3)}$ afin d'obtenir une segmentation initiale des zones d'ombre, des zones de végétation et des zones sombres (qui inclut les zones d'ombre et de végétation). La méthode d'Otsu est d'ailleurs très utilisée pour détecter l'ombre (Tsai, 2006) pour la qualité de ses résultats. Ainsi, l'image $Y^{(1)}$ est segmentée en deux classes ω_1 et $\{\omega_2, \omega_3\}$. De même, $Y^{(2)}$ est segmentée en les classes ω_2 et $\{\omega_1, \omega_3\}$ et $Y^{(3)}$ en les classes ω_3 et $\{\omega_1, \omega_2\}$. La théorie DS appliquée à la segmentation d'image permet alors de fusionner un par un les pixels provenant des trois segmentations et d'inférer sur les hypothèses (simples) H_i représentant les groupes simples : $H_i = \{\omega_i\}$. On note A une hypothèse simple ou une union d'hypothèses simples. Le cadre de discernement Θ regroupe l'ensemble des classes : $\Theta = \{\{\omega_1\}, \{\omega_2\}, \{\omega_3\}\}$.

Dans le cadre de la théorie DS, l'estimation des fonctions de masse est un problème difficile qui n'a pas de solution universelle. Plusieurs approches ont donc été proposées dans la littérature, par exemple, les fonctions à support simple (Shafer, 1976), les méthodes basées sur les densités de probabilités (Smets, 1993), la méthode utilisant des arbres de décisions (Vannoorenberghe, Denoeux, 2002) et celle utilisant les k -plus proches voisins (Denoeux, 1995). (Vannoorenberghe *et al.*, 1999) ont montré par des études empiriques qu'un bon modèle des fonctions de masse est basé sur un modèle de distributions gaussiennes et de seuillage de l'histogramme des images. Cette méthode simple est appliquée dans l'étude présente (notez qu'une méthode de détermination des fonctions de masse basée sur l'algorithme des c -moyennes floues FCM est aussi utilisée et on montrera les résultats obtenus dans la section 4 pour une comparaison).

La fonction de masse $m_s^{(1)}$ pour le pixel s de l'image $Y^{(1)}$, définie sur $\{\emptyset, A_1 = \{\omega_1\}, A_2 = \{\{\omega_2\}, \{\omega_3\}\}, \Theta\}$ est donc :

$$m_s^{(1)}(A_i) = \frac{1}{\sigma_i^{(1)} \sqrt{2\pi}} \exp \left(-\frac{(y_s^{(1)} - \mu_i^{(1)})^2}{2\sigma_i^{(1)2}} \right), \quad i \in \{1, 2\}$$

$$m_s^{(1)}(\emptyset) = 0, \quad m_s^{(1)}(\Theta) = \frac{1}{\sigma_\Theta^{(1)} \sqrt{2\pi}} \exp \left(-\frac{(y_s^{(1)} - \mu_\Theta^{(1)})^2}{2\sigma_\Theta^{(1)2}} \right) \quad (5)$$

où $y_s^{(1)}$ est la valeur du pixel s de l'image $Y^{(1)}$, $\mu_i^{(1)}$ (resp. $\sigma_i^{(1)}$) est la moyenne (resp. la variance) des pixels sous l'hypothèse A_i pour $Y^{(1)}$. Ces quantités sont estimées par :

$$\mu_i^{(1)} = \frac{1}{|A_i|} \sum_{s \in A_i} y_s^{(1)}, \quad \sigma_i^{(1)} = \sqrt{\frac{1}{|A_i| - 1} \sum_{s \in A_i} (y_s^{(1)} - \mu_i^{(1)})^2}, \quad i \in \{1, 2\}$$

$$\mu_\Theta^{(1)} = \frac{\mu_1^{(1)} + \mu_2^{(1)}}{2}, \quad \sigma_\Theta^{(1)} = \max(\sigma_1^{(1)}, \sigma_2^{(1)}) \quad (6)$$

où $|A_i|$ est le nombre de pixels sous l'hypothèse A_i .

Les fonctions de masse sont ensuite normalisées pour que leur somme soit égale à 1. Les fonctions de masse pour les images $Y^{(2)}$ et $Y^{(3)}$, définies respectivement sur $\{\emptyset, \{\omega_2\}, \{\{\omega_1\}, \{\omega_3\}\}, \Theta\}$ et $\{\emptyset, \{\omega_3\}, \{\{\omega_1\}, \{\omega_2\}\}, \Theta\}$, sont estimées de la même manière.

Les fonctions de masse des trois images étant estimées, leur combinaison est réalisée en utilisant la règle de combinaison de Dempster-Shafer (Dempster, 1968 ; Shafer, 1976). Cependant, cette règle assume l'indépendance des sources de l'information. Trois images caractéristiques c_3 , ExG, L viennent de la combinaison de trois bandes R, V, B. Ils ne sont donc pas trois sources indépendants. Dans une telle situation, la règle conjonctive prudente (notée $\hat{\Delta}$) de Denœux (Denœux, 2008 ; Denœux, 2006), qui permet de combiner les données dépendants, est utilisé. La fusion des données est illustrée figure 1.

Une fois que toutes les fonctions de masse des hypothèses simples et composées d'un pixel s sont déterminées, nous avons besoin d'un critère de décision pour décider quelle hypothèse est la plus réaliste. Pour la règle de combinaison prudente de Denœux, la décision s'effectue au niveau dit pignistique qui impose une transformation des fonctions de masses en distributions de probabilité.

$$Betp(H_i) = \sum_{\{A: H_i \in A\}} \frac{m(A)}{|A|} \quad (7)$$

où $|A|$ est le cardinal de l'ensemble des éléments de A .

1. le nombre (j) en exposant se réfère à l'image $Y^{(j)}$, $j \in \{1, 2, 3\}$

La décision consiste à choisir l'hypothèse simple de plus grande probabilité pignistique. Un exemple de la classification est représenté dans la figure 2.




FIGURE 1 – Diagramme de fusion




FIGURE 2 – Détection de l'ombre et de la végétation en utilisant la théorie de l'évidence et la règle de combinaison prudente. Dans la figure, les zones en noir correspondent à l'ombre, en vert la végétation, en blanc la classe « autre ».

3.3. Champ de Markov

La fusion des informations à l'aide de la théorie de DS travaille au niveau pixel : cela suppose implicitement que chaque pixel de l'image ne dépend pas de ses voisins, ce qui implique que la procédure reste très sensible au bruit. Nous allons donc utiliser un modèle de champ de Markov (Geman, Geman, 1984), souvent utilisé pour introduire de la dépendance spatiale. Cette hypothèse permet de déterminer la classe de chaque pixel en prenant en compte les classes des pixels proches, et éventuellement d'introduire une modélisation floue (Ruan *et al.*, 2002 ; Salzenstein *et al.*, 2007).

Soit \mathbf{X} un champ aléatoire sur l'ensemble \mathcal{S} des pixels, à valeurs dans un ensemble fini de classes $\Omega = \{\omega_1, \omega_2, \omega_3\}$. \mathbf{x} est une réalisation de \mathbf{X} et x_s est la valeur de \mathbf{x} au pixel $s \in \mathcal{S}$. Dans un champ de Markov, à partir des observations $\mathbf{Y} = (Y^{(1)}, Y^{(2)}, Y^{(3)})$, la carte de segmentation \mathbf{x} peut être obtenue en calculant l'estimation du maximum a posteriori (MAP):

$$\hat{\mathbf{x}}_{\text{MAP}} = \arg \max_x p(\mathbf{X} = \mathbf{x} | \mathbf{Y} = \mathbf{y}). \quad (8)$$

L'optimisation est effectuée à l'aide de l'algorithme ICM (*Iterated Conditional Modes*) (Besag, 1986). La loi a posteriori conditionnelle de \hat{x}_s s'écrit :

$$p(X_s = x_s | \mathbf{Y} = \mathbf{y}, \mathbf{X}_{S-\{s\}} = \hat{\mathbf{x}}_{S-\{s\}}) \quad (9)$$

$$\propto p(\mathbf{Y}_s = \mathbf{y}_s | X_s = x_s) \times p(X_s = x_s | \mathbf{X}_{\mathcal{V}_s} = \hat{\mathbf{x}}_{\mathcal{V}_s}) \quad (10)$$

où \mathcal{V}_s est un voisinage associé au pixel s . Dans notre implémentation, nous considérons un voisinage du second ordre (8-connexité) (Geman, Geman, 1984).

3.4. Théorie DS dans un contexte markovien

Au cours des dernières années, la théorie DS et les champs de Markov ont été utilisés dans des méthodes de classification, souvent dans le cas d'observations multisources (Bendjebbour *et al.*, 2001 ; Bentabet, Maodong, 2008 ; Pieczynski, 2007). Le cadre probabiliste attribue une vraisemblance $p(\mathbf{Y}_s = \mathbf{y}_s | X_s = x_s)$ uniquement aux classes $\omega_k \in \Omega$ ($k \in \{1, 2, 3\}$). En revanche, la théorie DS remplace cette vraisemblance par une fonction de masse sur $\{\omega_k\}$. Dans (Bentabet, Maodong, 2008), les auteurs proposent d'étendre le terme de vraisemblance $p(\mathbf{Y}_s = \mathbf{y}_s | X_s = x_s)$ en définissant la masse $m_s(A)$ pour tout $A \subset \Theta$. Ainsi, le terme de vraisemblance de l'équation 10 devient:

$$m_s(A) = m_s^{(1)} \oslash m_s^{(2)} \oslash m_s^{(3)} \quad (11)$$

pour tout $A \subset \Theta$. Ces fonctions de masses restent calculées comme présenté précédemment (diagramme 1).

Par ailleurs, afin de gérer les hypothèses composées $A \subset \Theta$, la probabilité a priori $p(X_s = x_s | \mathbf{X}_{\mathcal{V}_s} = \hat{\mathbf{x}}_{\mathcal{V}_s})$ (l'équation 10) peut être remplacée par :

$$m_s(A | \hat{\mathbf{x}}_{\mathcal{V}_s}) = \frac{\exp \left(- \sum_{H_k \cap A \neq \emptyset} \beta \sum_{l \in \mathcal{V}_s} \{1 - \delta(\omega_k, \hat{x}_l)\} \right)}{\sum_{B \subset \Theta} \exp \left(- \sum_{H_k \cap B \neq \emptyset} \beta \sum_{l \in \mathcal{V}_s} \{1 - \delta(\omega_k, \hat{x}_l)\} \right)} \quad (12)$$

où $H_k = \{\omega_k\}$, $A \subset \Theta$, et β est un paramètre du modèle markovien et $\delta(\cdot)$ représente la fonction de Kronecker définie par

$$\delta(x_s - x_l) = \begin{cases} 1 & \text{si } x_s = x_l \\ 0 & \text{sinon.} \end{cases} \quad (13)$$

Le paramètre β est estimé avec une méthode par moindres carrés proposée par (Derin, Elliott, 1987).

Enfin, considérant la vraisemblance et la probabilité a priori dans les équations (11) et (12) comme deux sources d'information évidentielles, la somme orthogonale de Dempster-Shafer est utilisée pour les combiner. La probabilité a posteriori exprimée dans l'équation (9) peut ainsi être remplacée par $M_s(\cdot)$, qui porte l'information jointe (Bendjebbour *et al.*, 2001 ; Bentabet, Maodong, 2008). Celle-ci est obtenue avec la règle de combinaison de Dempster :

$$M_s(A|\mathbf{y}_s, \hat{\mathbf{x}}_{\mathcal{V}_s}) = \frac{1}{1 - \mathcal{K}} \sum_{A_p \cap A_q = A} m_s(A_p) m_s(A_q | \hat{\mathbf{x}}_{\mathcal{V}_s}) \quad (14)$$

$$\text{où } \mathcal{K} = \sum_{A_p \cap A_q = \emptyset} m_s(A_p) m_s(A_q | \hat{\mathbf{x}}_{\mathcal{V}_s}).$$

Une fois que toutes les fonctions de masse des hypothèses simples et composées d'un pixel s sont déterminées, \hat{x}_s est estimé en maximisant la fonction de plausibilité sur l'information jointe :

$$\hat{x}_s = \arg \max_{x_s} \text{Pls}(H_{x_s}) = \arg \max_{x_s} \left(\sum_{A \cap H_{x_s} \neq \emptyset} M_s(A|\mathbf{y}_s, \hat{\mathbf{x}}_{\mathcal{V}_s}) \right) \quad (15)$$

3.5. Algorithme global

La méthode de fusion itérative proposée prend comme entrée l'image couleur RVB et la sortie est une image classifiée \mathbf{x} avec trois classes : « ombre », « végétation », « autre ». Les étapes de l'algorithme sont détaillés dans l'algorithme 1. L'algorithme ICM opère jusqu'à ce que le pourcentage d'étiquetages modifiées entre deux itérations consécutives ou que le nombre d'itérations n'atteigne une valeur prédéfinie (ϵ et τ_{max}). Pour les résultats présentés, ces valeurs sont respectivement 0.2 % et 100.

4. Résultats obtenus

Les tests sont réalisés sur des images aériennes NOAA tri-bande (R,V,B ; 8 bits par pixel pour chaque bande) avec une résolution spatiale de 24 cm, fournies par le SERTIT (sertit.u-strasbg.fr), dans le cadre du projet Kal-Haïti. Dans cette section, nous analysons la fonctionnalité de chaque étape de la méthode proposée figure 3. Puis, nous évaluons la méthode proposée tant qualitativement que quantitativement et la comparons à trois algorithmes de l'état de l'art. Les résultats résumés dans les tables 3 et 4 montrent que notre méthode a la meilleure précision globale (définie table 1) tant pour la détection d'ombre que pour la détection de végétation.

4.1. Méthode d'évaluation

L'évaluation est effectuée en calculant le taux de vrais positifs (VP), faux négatifs (FN), faux positifs (FP) et vrai négatifs (VN). Pour l'évaluation quantitative nous

Algorithme 1 : Algorithme global pour détecter l'ombre et la végétation/* **Entrées** */

- Image RVB.
- Nombre maximum d'itérations τ_{max} .
- Erreur ϵ .

/* **Initialisation** */

- Calculer c_3 , ExG, L qui correspondent à $Y^{(1)}$, $Y^{(2)}$, $Y^{(3)}$.
- Appliquer le seuillage d'Otsu pour $Y^{(1)}$, $Y^{(2)}$, $Y^{(3)}$.
- Pour chaque $Y^{(j)}$, $j \in \{1, 2, 3\}$, calculer $\mu_i^{(j)}$, $\sigma_i^{(j)}$, $i \in 1, 2$ en utilisant l'équation 6.

pour chaque pixel $s \in \mathcal{S}$ **faire**

- Pour $j \in \{1, 2, 3\}$, et $i \in \{1, 2\}$, calculer $m_s^{(j)}(A_i)$, $m_s^{(j)}(\Theta)$, en utilisant l'équation 5.
- Calculer la somme de combinaison prudente: $m_s(A)$ pour tout $A \subset \Theta$ (figure 1).
- $\hat{x}_s = \arg \max_{x_s} Betp(H_{x_s})$

 $\mathbf{x}^{[0]} \leftarrow \mathbf{x}$: configuration initiale/* **Algorithme ICM** */ $k = 0$; /* nombre d'itération */**répéter**

1. Estimation des paramètres:

- Mettre à jour: $\mu_i^{(j)}$, $\sigma_i^{(j)}$, $i \in \{1, 2\}$, $j \in \{1, 2, 3\}$ à partir de $Y^{(1)}$, $Y^{(2)}$, $Y^{(3)}$, $\mathbf{x}^{[k]}$ en utilisant l'équation 6.
- Mettre à jour: β en utilisant une méthode par moindres carrés proposée par (Derin, Elliott, 1987).

2. Calcul de $\mathbf{x}^{[k+1]}$ à partir de $\mathbf{x}^{[k]}$:**pour** chaque pixel $s \in \mathcal{S}$ **faire**/* On balaie l'ensemble des sites s (selon une stratégie de visite de sites) */

- Pour $j \in \{1, 2, 3\}$, et $i \in \{1, 2\}$, calculer $m_s^{(j)}(A_i)$, $m_s^{(j)}(\Theta)$ en utilisant l'équation 5.
- Calculer $m_s(A)$ pour tout $A \subset \Theta$ (figure 1).
- Calculer $m_s(A|\hat{x}_{\mathcal{V}_s})$ pour tout $A \subset \Theta$ en utilisant l'équation 12.
- Calculer $M_s(A)$ pour tout $A \subset \Theta$ en utilisant l'équation 14.
- Estimer:

$$\hat{x}_s = \arg \max_{x_s} \text{Pls}(H_{x_s}) = \arg \max_{x_s} \left(\sum_{A \cap H_{x_s} \neq \emptyset} M_s(A|\mathbf{y}_s, \hat{\mathbf{x}}_{\mathcal{V}_s}) \right)$$

 $\mathbf{x}^{[k+1]} \leftarrow \mathbf{x}$ $k \leftarrow k + 1$ **jusqu'à** $(|\mathbf{x}^{[k+1]} - \mathbf{x}^{[k]}| \leq \epsilon) \vee (k \geq \tau_{max})$;/* **Sortie** */- carte de segmentation $\hat{\mathbf{x}} \leftarrow \mathbf{x}^{[k]}$.

Précision du photointerpréteur		Précision de l'utilisateur	
Ombre (rappel)	Non-ombre	Ombre (précision)	Non-ombre
$P_s = \frac{VP}{VP + FN}$	$P_n = \frac{VN}{VN + FP}$	$U_s = \frac{VP}{VP + FP}$	$U_n = \frac{VN}{VN + FN}$
Précision totale			
$\tau = \frac{VP + VN}{VP + VN + FP + FN}$			

TABLE 1 – Métrique et table de précision

adoptons la même métrique et table de précision que ceux proposés dans (Prati *et al.*, 2003) (table 1). En ce qui concerne les ombres, VP est le nombre de pixels ombrés correctement identifiés, FN est le nombre de pixels ombrés considérés comme non ombragés, FP est le nombre de pixels non ombrés considérés comme étant de l'ombre et VN est le nombre de pixels non ombrés correctement identifiés. Ces paramètres sont définis de la même manière pour la détection de la végétation. La somme VP + FN + FP + VN correspond donc au nombre total de pixels dans l'image. La précision du photointerpréteur indique comment les pixels des catégories connues sont correctement classés. La précision de l'utilisateur indique la probabilité de pixels correctement classés par rapport à la référence qui est ici le photointerpréteur. En combinant ces indices de précision, on obtient la précision générale τ qui permet d'évaluer la performance de l'algorithme. Des valeurs de paramètres élevées correspondent à de bons résultats.

4.2. Performances des étapes de l'algorithme

Nous analysons dans un premier temps le bon fonctionnement de chaque étape de la méthode proposée. L'approche proposée détermine, à partir des images caractéristiques issues des indices c_3 , ExG et L, une carte de segmentation \mathbf{x} en trois classes (« ombre », « végétation », « autre »). L'initialisation correspond à un seuillage d'Otsu (Otsu, 1975) suivi d'une fusion DS qui fait l'hypothèse d'une distribution gaussienne pour la détermination des fonctions de masse. Nous comparons cette initialisation avec la fusion DS qui emploie l'algorithme des c-moyennes floues FCM pour calculer les fonctions de masse (appelé FCM_DS). Après plusieurs itérations de l'ICM, on obtient la segmentation finale. Les résultats obtenus sont présentés figure 3. Dans la figure, les étapes de traitement sont représentées : un seuillage d'Otsu pour détecter uniquement l'ombre, un seuillage d'Otsu pour détecter uniquement la végétation, l'initialisation de notre algorithme, la méthode FCM_DS et le résultat final.

La figure 3 représente une zone peu urbanisée contenant beaucoup de végétation et des bâtiments impliquant des ombres portées. On constate que les zones d'ombre sont obtenues avec une grande précision grâce à la régularisation spatiale (cercle rouge) : les petites zones isolées d'ombre sont supprimées et la forme de l'ombre est préservée. Comme les zones construites possèdent à peu près le même indice c_3 que les zones d'ombre, elles sont classées comme telles dans la figure 3-(c). Pour une rai-

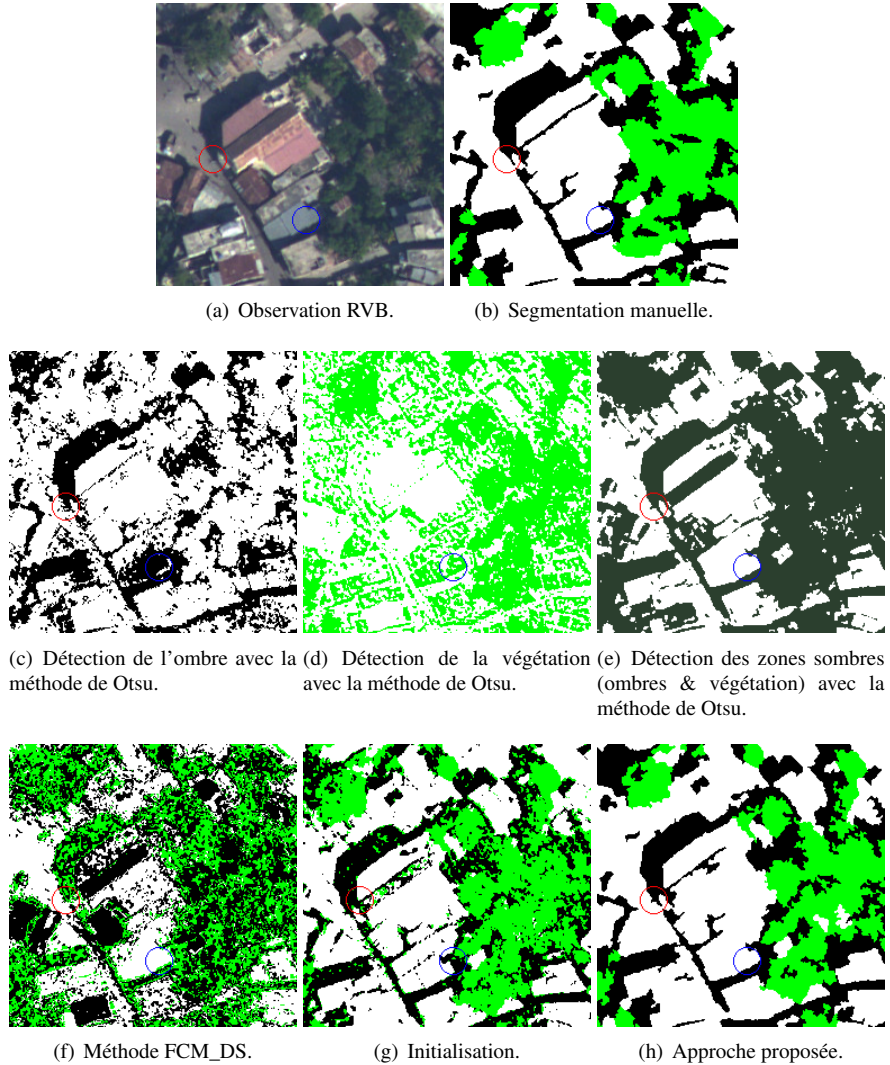


FIGURE 3 – Segmentation des ombres (en noir), de la végétation (en vert) et du reste (en blanc) d'une zone peu urbanisée.

son similaire, les zones construites sont considérées à tort comme de la végétation dans la figure 3-(d) (cercle bleu). L'utilisation de la luminance L permet de corriger ces erreurs : les bâtiments ne sont pas considérés comme des zones sombres dans la figure 3-(e). La fusion DS utilisant l'hypothèse de distribution gaussienne pour le calcul de la fonction de masse donne le meilleur résultat (figure 3-(g)) comparé à la fusion DS utilisant l'algorithme FCM (figure 3-(f)). On observe que la méthode proposée (figure 3-(h)) donne le résultat le plus proche de la segmentation manuelle considé-

rée comme la vérité terrain (figure 3-(b)) : elle résout les mauvaises classifications et améliore la précision de la segmentation. Sans régularisation spatiale, on obtient une segmentation très parcellisée (figure 3-(g)). On a également mesuré quantitativement l'apport de la régularisation par champ de Markov. La table 2 montre que l'initialisation avec la fusion DS qui fait l'hypothèse d'une distribution gaussienne (figure 3-(g)) est meilleure que l'initialisation avec la fusion DS qui emploie l'algorithme des c-moyennes floues (figure 3-(f)) et avec la régularisation MRF, on obtient la meilleure précision globale.

Détection des ombres					
Méthode	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Ombre	Non-ombre	Ombre	Non-ombre	τ
Détection de l'ombre avec la méthode de Otsu (figure 3.c)	79.59	99.60	98.80	92.18	93.74
Méthode FCM_DS (figure 3.f)	84.86	46.76	28.35	92.56	54.33
Initialisation (figure 3.g)	83.32	97.14	96.17	93.28	94.32
Méthode proposée (figure 3.h)	92.35	99.93	99.82	96.93	97.71
Détection de la végétation					
Méthode	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Végétation	Non-végétation	Végétation	Non-végétation	τ
Détection de la végétation avec la méthode de Otsu (figure 3.d)	94.17	43.57	10.20	99.09	46.80
Méthode FCM_DS (figure 3.f)	78.06	96.25	93.24	86.89	89.01
Initialisation (figure 3.g)	96.39	91.23	40.81	99.16	91.11
Méthode proposée (figure 3.h)	99.25	98.37	80.60	99.94	98.42

TABLE 2 – Qualité de la segmentation pour l'image représentée dans la figure 3. Les valeurs sont données en pourcentage.

4.3. Comparaison avec l'état de l'art

L'approche proposée est comparée aux approches standards. Pour la détection d'ombre, nous comparons notre méthode à l'algorithme donné dans (Tian *et al.*, 2012). Comme décrit dans (Adeline *et al.*, 2013), la chrominance de l'ombre peut être exploitée en combinant les bandes RVB (par exemple, en utilisant l'indice c_3), ou en travaillant avec des images où l'ombre est invariante (par exemple, atténuation tricolore (TAM), proposé par (Tian *et al.*, 2009)). Le modèle d'atténuation tricolore décrit la relation d'atténuation entre des ombres et leur voisinage dans les trois canaux et les combine avec le canal d'intensité pour détecter les ombres. Dans (Tian *et al.*,

2009), les auteurs ont sur-segmenté l'image en différentes régions, et puis appliqué le modèle TAM pour décider quels régions sont l'ombre. En fait, le fait d'utiliser plusieurs seuils rend cette approche instable. Dans (Tian *et al.*, 2012), ils ont amélioré le modèle TAM, n'utilisent plus la segmentation et utilisent une seule seuil, qui permet d'avoir les meilleurs résultats. De plus, les codes de cette méthode sont disponibles librement sur Internet (Tian, 2012). Pour la détection de végétation, nous comparons notre méthode avec celle proposée par (Shorter, Kasparis, 2009). Dans leur travail, l'image est d'abord segmentée en utilisant une technique de quantification colorée. Le pixel candidat à l'étiquette végétation est identifié par seuillage de type Otsu et un modèle invariant de couleur. Les régions identifiées par l'algorithme de segmentation sont classifiées comme de la végétation si et seulement si elles contiennent plus de 60% de pixels de végétation. Parce que la méthode est basée région, la dépendance spatiale est de facto prise en compte et permet une comparaison avec notre approche. Il est à noter que ces méthodes produisent deux images binaires correspondants aux masques végétation et ombre tandis que notre approche produira une carte de segmentation à trois classes : « ombre », « végétation » et « autre ». De plus, nous avons testé un nouvel index *SVI shadow-vegetation indice* défini de la manière suivante : $SVI = c_3 - ExG$. Pour générer ce nouvel indice, nous calculons c_3 grâce à l'équation 1 et ExG grâce à l'équation 2, puis nous normalisons ces valeurs entre 0 et 1. Un algorithme des k-moyennes classe alors en trois classes : « ombre », « végétation » et « autre ». Le résultat de classification est régularisé en utilisant une modélisation par champ de Markov avec un terme d'attache aux données gaussien et un voisinage du second ordre (8-connexité) (Geman, Geman, 1984). La minimisation de l'énergie est réalisée grâce à un algorithme itératif ICM où les paramètres du terme d'attache aux données sont mis à jour (μ et σ) à chaque itération tandis que les potentiels du terme a priori β sont estimés par la méthode de Derin et Elliot (Derin, Elliott, 1987), également à chaque itération. Cette nouvelle méthode de détection ombre/végétation est notée SVI-ICM dans la suite.

Les figures 4 et 5 montrent les masques d'ombre et de végétation pour les quatre méthodes. Nous observons que la méthode de (Tian *et al.*, 2012) détecte tout à fait bien les régions d'ombre (particulièrement dans la figure 5), mais elle classe toutes les régions de végétation comme classe ombre, par exemple, la région marquée par le cercle bleu. Cette région est correctement classifiée comme la région de végétation par la méthode de (Shorter, Kasparis, 2009). De nouveau, la région marquée par le cercle rouge est à tort classifiée comme la région de végétation (par (Shorter, Kasparis, 2009), mais (Tian *et al.*, 2012) détecte correctement cette région comme la région d'ombre. Ces zones peuvent être classifiées comme zones de végétation (par un algorithme de détection de végétation, figure 4-(d) et figure 5-(d)), et en même temps comme zones d'ombre (par un algorithme de détection d'ombre, figure 4-(c) et figure 5-(c)). En détectant simultanément l'ombre et la végétation, notre méthode permet d'obtenir une carte de segmentation plus satisfaisante (figure 4-(f) et figure 5-(f)). Les figures 4-(e), 5-(e) montrent visuellement que les zones ombre et végétation sont généralement correctement détectées, toutefois, quelques zones de végétation manquent à la détection

(4-(e), cercle magenta) et la forme des régions ombre peut être mis en défaut (5-(e), cercle magenta).

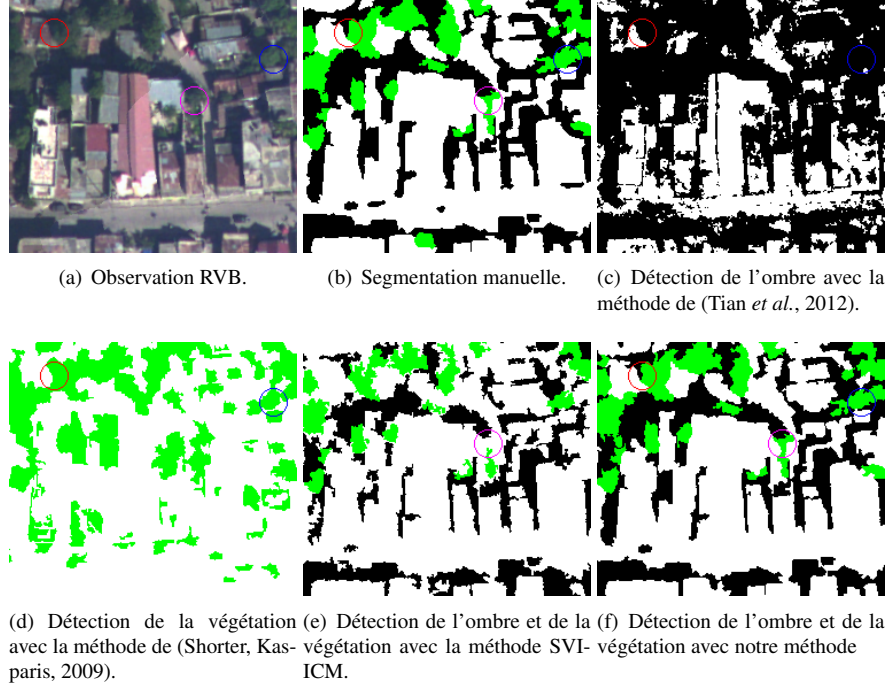


FIGURE 4 – Segmentation des ombres (en noir), de la végétation (en vert) et du reste (en blanc) d'une zone urbaine.

Les tables 3 et 4 donnent les précisions obtenues pour la détection d'ombre utilisant la méthode de (Tian *et al.*, 2012), la détection de végétation utilisant la méthode de (Shorter, Kasparis, 2009), la méthode de SVI-ICM et notre méthode. On montre que notre méthode a la meilleure précision globale pour les deux images, tant pour ce qui concerne la détection d'ombre que pour la détection de végétation.

5. Discussion

Les techniques conventionnelles de segmentation d'images supposent que tous les pixels dans l'image sont purs, en somme, qu'ils représentent une zone de couverture homogène, décrite par une unique classe. Cette supposition est parfois mise en défaut avec les pixels de composition mélangée. De plus, une résolution spatiale trop faible crée des pixels de mélange chaque fois que la source ne peut pas distinguer deux classes. Comme la théorie de l'évidence peut traiter n'importe quelle union de classes, il est particulièrement utile de représenter les pixels de mélange dans des problèmes de classification.

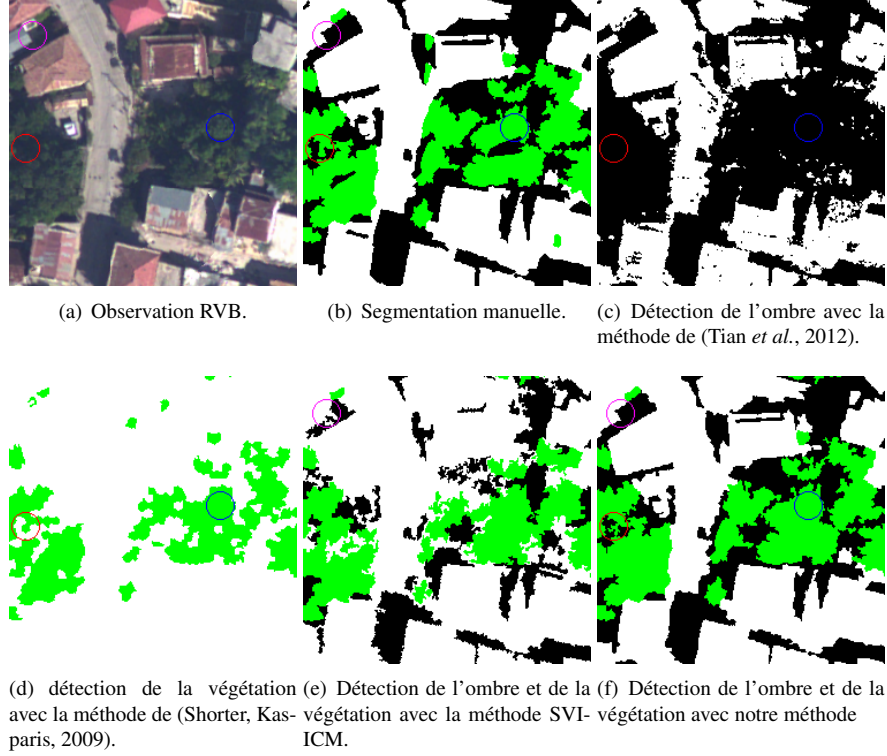


FIGURE 5 – Segmentation des ombres (en noir), de la végétation (en vert) et du reste (en blanc) d'une zone urbaine.

À côté de trois classes pures, « ombre », « végétation », « autre », nous définissons une nouvelle classe de mélange ω_4 , qui correspond au mélange « végétation - ombre » (végétation couverte par l'ombre). Le synoptique de fusion de données de la figure 1 est modifié et illustré dans la figure 6.




FIGURE 6 – Diagramme de fusion

Pour le reste, cette nouvelle approche est similaire à celle présentée dans l'algorithme 1. Les résultats obtenus sont présentés figure 7, dans laquelle les zones en cyan correspondent à la classe ω_4 . Comme attendu, le mélange ombre-végétation est sur-

Méthode	Détection des ombres				
	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Ombre	Non-ombre	Ombre	Non-ombre	τ
Méthode de (Tian <i>et al.</i> , 2012)	95.70	49.99	49.32	95.80	65.40
Méthode SVI-ICM	72.24	97.65	93.99	87.37	89.08
Méthode proposée	89.19	99.14	98.15	94.74	95.79

Méthode	Détection de la végétation				
	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Végétation	Non-végétation	Végétation	Non-végétation	τ
Méthode de (Shorter, Kasparis, 2009)	85.03	80.77	36.28	97.66	81.25
Méthode SVI-ICM	64.79	99.13	90.56	95.62	95.21
Méthode proposée	93.25	99.04	92.60	99.13	98.38

TABLE 3 – Qualité de la segmentation pour l'image représentée dans la figure 4. Les valeurs sont données en pourcentage.

Méthode	Détection des ombres				
	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Ombre	Non-ombre	Ombre	Non-ombre	τ
Méthode de (Tian <i>et al.</i> , 2012)	95.10	61.09	53.13	96.41	71.87
Méthode SVI-ICM	60.30	98.65	95.42	84.27	86.50
Méthode proposée	89.29	98.94	97.51	95.21	95.88

Méthode	Détection de la végétation				
	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Végétation	Non-végétation	Végétation	Non-végétation	τ
Méthode de (Shorter, Kasparis, 2009)	77.04	97.18	88.61	93.70	92.72
Méthode SVI-ICM	75.31	97.61	89.97	93.29	92.67
Méthode proposée	94.73	98.45	94.58	98.50	97.63

TABLE 4 – Qualité de la segmentation pour l'image représentée dans la figure 5. Les valeurs sont données en pourcentage.

tout observé aux frontières des classes pures (des régions d'ombre ou des régions de végétation) ce qui rend très plausible les résultats). Visuellement, on s'aperçoit que beaucoup de zones considérées comme de la végétation ombragée ne sont pas détectées. Cela dit, les zones détectées correspondent bien à des zones de végétation ombragée. La table 5 montre une précision totale de 97.66%. Cependant, le rappel de la précision du photointerpréteur est faible : 41.28%. Cela signifie bien que la méthode sous-détecte la végétation ombragée.

Mais le point intéressant ici consiste à regarder les résultats préliminaires obtenus grâce à la méthode de détection ombre/végétation proposée appliqué à la détection de

Détection des ombres					
Méthode	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Ombre	Non-ombre	Ombre	Non-ombre	τ
Méthode proposée	96.45	94.74	88.76	98.41	95.26

Détection de la végétation					
Méthode	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Végétation	Non-végétation	Végétation	Non-végétation	τ
Méthode proposée	93.15	99.52	97.96	98.34	98.27

Détection de la végétation ombragée					
Méthode	Précision du photointerpréteur		Précision de l'utilisateur		Précision totale
	Végétation ombragée	Non-végétation ombragée	Végétation ombragée	Non-végétation ombragée	τ
Méthode proposée	41.28	100	100	97.62	97.66

TABLE 5 – Qualité de la segmentation pour l'image représentée dans la figure 7. Les valeurs sont données en pourcentage.




FIGURE 7 – Résultats de segmentation. Les observations sont présentées sur la première ligne et les segmentations sur la seconde : ombre (noir), végétation (vert), ombre-végétation (cyan) et autre (blanc).

bâtiment avant/après crise, cf figure 8. Les bâtiments doivent être classés en 3 classes : bâtiment construit, bâtiment en cours de construction, bâtiment en ruine. Cette classification se base principalement sur la distribution et la densité des zones d'ombre et de végétation détectées. Dans la figure 8, le bâtiment avant-crise est classifié comme bâtiment construit car l'ombre et la végétation sont en dehors de la zone de bâti. À l'inverse, en post-crise, le bâtiment est classifié « en construction » à cause des nombreux petites régions d'ombre à l'intérieur de la zone de bâti : les régions d'ombre sont supposées correspondre aux ombres portées des murs. Pour un bâtiment en ruine, la différence avec un bâtiment en cours de construction vient de la présence de végétation ombragée dans la zone de bâti, produite par la présence de végétation en croissance dans ce qui est maintenant une ruine. Dans ce contexte, une perspective pourrait consister à faire la différence entre bâtiment en construction et bâtiment en ruine grâce à cette classe mélange ombre/végétation.



FIGURE 8 – Deux exemples de détection ombre/végétation pour la classification des bâtiments. Les 2 lignes correspondent respectivement aux images avant et après une catastrophe.

6. Conclusions

Une méthode prometteuse est présentée pour détecter des zones d'ombres et de végétation dans des images aériennes, utilisant la théorie de l'évidence et le modèle de champ de Markov pour la régularisation. La procédure de fusion permet de combiner différents indices: c_3 pour l'ombre, ExG pour la végétation et la luminance L pour les zones sombres. La corrélation spatiale entre pixels est prise en compte dans le modèle markovien pour finalement obtenir une carte de segmentation plus robuste. Une comparaison quantitative entre cette méthode et deux algorithmes de l'état de l'art pour la détection d'ombre et de la végétation indique clairement que cette méthode donne de meilleurs résultats de détection dans des images aériennes. Cette méthode a pour en outre intérêt de considérer également la classe mélange (végétation dans une zone d'ombre).

Remerciement

Nous remercions le Service régional de traitement d'image et de télédétection (sertit.u-strasbg.fr) pour nous avoir fourni les données, ainsi que l'Institut Carnot (www.instituts-carnot.eu) et la Région Alsace pour le financement de la thèse. Nous remercions les relecteurs anonymes pour les suggestions ayant permis d'approfondir certains points de l'article.

Bibliographie

- Adeline K., Chen M., Briottet X., Pang S., Paparoditis N. (2013). Shadow detection in very high spatial resolution aerial images: A comparative study. *ISPRS J. Photogramm. Remote Sens.*, vol. 80, p. 21–38.
- Aitkenhead M., Dalgetty I., Mullins C., McDonald A., Strachan N. (2003). Weed and crop discrimination using image analysis and artificial intelligence methods. *Comput. Electron. Agr.*, vol. 39, n° 3, p. 157–171.
- Arévalo V., González J., Ambrosio G. (2008). Shadow detection in colour high resolution satellite images. *Int. J. Remote Sens.*, vol. 29, n° 7, p. 1945–1963.
- Bendjebbour A., Delignon Y., Fouque L., Samson V., Pieczynski W. (2001). Multisensor image segmentation using Dempster-Shafer fusion in Markov fields context. *IEEE Trans. Geosci. Remote Sens.*, vol. 39, n° 8, p. 1789–1798.
- Bentabet L., Maodong J. (2008). A combined Markovian and Dirichlet sub-mixture modeling for evidence assignment: Application to image fusion. *Pattern Recogn. Lett.*, vol. 29, n° 13, p. 1775–1783.
- Besag J. (1986). On the statistical analysis of dirty picture. *J. R. Stat. Soc.*, vol. 48, n° 3, p. 259–302.
- Boudraa A.-O., Bentabet A., Salzenstein F., Guillon L. (2004). Dempster-shafer's basic probability assignment based on fuzzy membership functions. *Electronic Letters on Computer Vision and Image Analysis*, vol. 4, n° 1, p. 1–9.
- Chen C.-T., Su C.-Y., Kao W.-C. (2010). An enhanced segmentation on vision-based shadow removal for vehicle detection. In *2010 ICGCS*, p. 679–682.
- Cucchiara R., Grana C., Piccardi M., Prati A. (2003). Detecting moving objects, ghosts, and shadows in video streams. *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 25, n° 10, p. 1337–1342.
- Dempster A. P. (1968). A generalization of Bayesian inference. *J. R. Stat. Soc., Series B (Methodological)*, p. 205–247.
- Denceux T. (2006). The cautious rule of combination for belief functions and some extensions. In *Information fusion, 2006 9th international conference on*, p. 1–8.
- Denoeux T. (1995, mai). A k-nearest neighbor classification rule based on dempster-shafer theory. *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 25, n° 5, p. 804–813.
- Denceux T. (2008). Conjunctive and disjunctive combination of belief functions induced by nondistinct bodies of evidence. *Artificial Intelligence*, vol. 172, n° 2, p. 234–264.
- Derin H., Elliott H. (1987). Modeling and segmentation of noisy and textured images using Gibbs random fields. *IEEE Trans. Pattern Anal. Mach. Intell.*, n° 1, p. 39–55.
- Geman S., Geman D. (1984). Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 6, n° 6, p. 721–41.
- Gevers T., Smeulders A. W. M. (1999). Color-based object recognition. *Pattern recogn.*, vol. 32, n° 3, p. 453–464.
- Hathaway R. J., Bezdek J. C., Pedrycz W. (1996). A parametric model for fusing heterogeneous fuzzy data. *Fuzzy Systems, IEEE Transactions on*, vol. 4, n° 3, p. 270–281.

- Huang J., Xie W., Tang L. (2004). Detection of and compensation for shadows in colored urban aerial images. *2004 WCICA*, vol. 4, n° 1, p. 3098–3100.
- Kataoka T., Kaneko T., Okamoto H., Hata S. (2003). Crop growth estimation system using machine vision. In *2003 IEEE/ASME*, p. 1079–1083.
- Le Hegarat-Masclé S., Bloch I., Vidal-Madjar D. (1997). Application of Dempster-Shafer evidence theory to unsupervised classification in multisource remote sensing. *IEEE Transactions on Geoscience and Remote Sensing*, vol. 35, n° 4, p. 1018–1031.
- Marchant J. A., Tillett R. D., Brivot R. (1998). Real-time segmentation of plants and weeds. *Real-time imaging*, vol. 4, n° 4, p. 243–253.
- Meyer G. E., Neto J. C. (2008). Verification of color vegetation indices for automated crop imaging applications. *Computers and Electronics in Agriculture*, vol. 63, n° 2, p. 282–293.
- Meyer G. E., Neto J. C., Jones D. D., Hindman T. W. (2004, mars). Intensified fuzzy clusters for classifying plant, soil, and residue regions of interest from color images. *Comput. Electron. Agr.*, vol. 42, n° 3, p. 161–180.
- Mohammad-Djafari A. (1998). Probabilistic methods for data fusion. In *Maximum entropy and bayesian methods*, p. 57–69. Springer.
- Neto J. C., Meyer G., Jones D. (2006). Individual leaf extractions from young canopy images using Gustafson-Kessel clustering and a genetic algorithm. *Comput. Electron. Agr.*, vol. 51, p. 66–85.
- Otsu N. (1975). A threshold selection method from gray-level histograms. *Automatica*, vol. 11, n° 285-296, p. 23–27.
- Ozgun Ok A. (2013). Automated detection of buildings from single VHR multispectral images using shadow information and graph cuts. *ISPRS J. Photogramm. Remote Sens.*, vol. 86, p. 21–40.
- Phong B. T. (1975). Illumination for computer generated pictures. *Commun. ACM*, vol. 18, n° 6, p. 311–317.
- Pieczynski W. (2007). Multisensor triplet markov chains and theory of evidence. *Int. J. of Approx. Reason.*, vol. 45, n° 1, p. 1–16.
- Polidorio A. M., Flores F. C., Imai N. N., Tommaselli A. M., Franco C. (2003). Automatic shadow segmentation in aerial color images. In *2003 SIBGRAPI*, p. 270–277.
- Ponti M. P. (2013). Segmentation of low-cost remote sensing images combining vegetation indices and mean shift. *IEEE Geosci. Remote Sens. Lett.*, vol. 10, n° 1, p. 67–70.
- Prati A., Mikic I., Trivedi M. M., Cucchiara R. (2003). Detecting moving shadows: algorithms and evaluation. *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 25, n° 7, p. 918–923.
- Reid J., Searcy S. (1987). Vision-based guidance of an agriculture tractor. *IEEE Contr. Syst. Mag.*, vol. 7, n° 2, p. 39–43.
- Rouse, JW, Haas, RH, Schell, JA, Deering, DW, Harlan, JC. (1974). *Monitoring the vernal advancement and retrogradation (greenwave effect) of natural vegetation*. Texas A & M University, Remote Sensing Center.
- Ruan S., Moretti B., Fadili J., Bloyet D. (2002). Fuzzy markovian segmentation in application of magnetic resonance images. *Comput. Vis. Image Understand.*, vol. 85, n° 1, p. 54–69.

- Salvador E., Cavallaro A., Ebrahimi T. (2001). Shadow identification and classification using invariant color models. In *ICASSP'01*, vol. 3, p. 1545–1548.
- Salvador E., Cavallaro A., Ebrahimi T. (2004). Cast shadow segmentation using invariant color features. *Comput. Vis. Image Understand.*, vol. 95, n° 2, p. 238–259.
- Salzenstein F., Collet C., Lecam S., Hatt M. (2007). Non-stationary fuzzy Markov chain. *Pattern Recognit. Lett.*, vol. 28, n° 16, p. 2201–2208.
- Shafer G. (1976). *A mathematical theory of evidence* (vol. 1). Princeton University Press.
- Shorter N., Kasparis T. (2009). Automatic vegetation identification and building detection from a single nadir aerial image. *Remote Sensing*, vol. 1, n° 4, p. 731–757.
- Smets P. (1993). Belief functions: the disjunctive rule of combination and the generalized bayesian theorem. *Int. J. of Approx. Reason.*, vol. 9, n° 1, p. 1–35.
- Sun B., Li S. (2010). Moving cast shadow detection of vehicle using combined color models. In *CCPR*, p. 1–5.
- Tellaeche A., BurgosArtizzu X. P., Pajares G., Ribeiro A., Fernandez-Quintanilla C. (2008). A new vision-based approach to differential spraying in precision agriculture. *Comput. Electron. Agr.*, vol. 60, n° 2, p. 144–155.
- Tian J. (2012). *MATLAB Source Codes for Shadow detection*. <http://vision.sia.cn/our%20team/JiandongTian/JiandongTian.html>.
- Tian J., Sun J., Tang Y. (2009, octobre). Tricolor attenuation model for shadow detection. *IEEE transactions on image processing*, vol. 18, n° 10, p. 2355–63. Consulté sur <http://www.ncbi.nlm.nih.gov/pubmed/19586816>
- Tian J., Zhu L., Tang Y. (2012). Outdoor shadow detection by combining tricolor attenuation and intensity. *EURASIP J. Adv. Signal Process.*, p. 1–8.
- Tsai V. J. (2006, juin). A comparative study on shadow compensation of color aerial images in invariant color models. *IEEE Trans. Geosci. Remote Sens.*, vol. 44, n° 6, p. 1661–1671.
- Tucker, Compton J. (1979). Red and photographic infrared linear combinations for monitoring vegetation. *Remote sens. Environ.*, vol. 8, n° 2, p. 127–150.
- Vannoorenberghe P., Colot O., Brucq D. de. (1999). Color image segmentation using dempster-shafer's theory. In *ICIP 1999*, vol. 4, p. 300–304.
- Vannoorenberghe P., Denoeux T. (2002). Handling uncertain labels in multiclass problems using belief decision trees. In *Proceedings of IPMU*, vol. 3, p. 1919–1926.
- Woebbecke D. M., Meyer G. E., Von Bargen K., Mortensen D. A. (1995). Color indices for weed identification under various soil, residue, and lighting conditions. *Transactions of the ASAE*, vol. 38, n° 1, p. 259–269.
- Yao J., Zhang Z. M. (2006). Hierarchical shadow detection for color aerial images. *Comput. Vis. Image Understand.*, vol. 102, n° 1, p. 60–69.
- Zheng L., Shi D., Zhang J. (2010). Segmentation of green vegetation of crop canopy images based on mean shift and Fisher linear discriminant. *Pattern Recognit. Lett.*, vol. 31, n° 9, p. 920–925.